Unidad 1 · Prueba de hipótesis: valor p, región de rechazo y errores

Qué vas a poder hacer. Traducir una pregunta del negocio a una hipótesis nula y una alternativa, elegir la cola, calcular el estadístico y su valor p (o compararlo con la región de rechazo), decidir y decirlo en el lenguaje del problema; estimar la probabilidad de equivocarte en cada dirección, calcular la potencia y el tamaño de muestra de una prueba para una media, y leer la misma decisión en un intervalo de confianza. Todo a mano y confirmado con `scipy`.

Lo que necesitas antes. De Probabilidades y Estadística: la distribución normal y la t de Student (leer sus tablas), el teorema central del límite y el intervalo de confianza para una media. Es la primera unidad del ramo: no requiere otra.

Tiempo. Unas 6 horas: 2,5 de lectura con el ejemplo y el cuaderno, 3,5 de práctica.

---

1. La idea · suponer lo aburrido y ver si los datos lo desmienten

Una prueba de hipótesis es un argumento por contradicción con ruido. Se parte de una afirmación aburrida (la máquina está bien, la campaña no cambió nada, los sacos pesan lo que dicen) y se pregunta: **si eso fuera cierto, ¿qué tan raro sería ver datos como los que vi?** Si serían muy raros, la afirmación aburrida pierde credibilidad y se descarta. Si no serían raros, se mantiene, no porque esté probada sino porque los datos no alcanzan para descartarla.

Es el mismo razonamiento de un juicio: el acusado es inocente mientras la evidencia no supere una duda razonable. «No culpable» no significa «inocente»: significa que no hubo prueba suficiente.

Por qué importa. En una planta todo varía. Si cada vez que una medición sale alta se ajusta la máquina, se persigue ruido. La prueba de hipótesis da una regla, fijada antes de mirar los datos, para separar una diferencia real de una que el azar produce solo.

2. Las piezas y los cinco pasos

Pieza	Qué es	Ejemplo (sacos de 15 kg)
Parámetro	lo que se quiere saber de la población	μ: peso medio de todos los sacos
H_0, hipótesis nula	el estado aburrido, con un signo igual	$\mu = 15$ kg
H_1, hipótesis alternativa	lo que se quiere mostrar con evidencia	$\mu < 15$ kg
Estadístico de prueba	número calculado con la muestra que mide la distancia a H_0	$t = (\bar{x} - 15)/(s/\sqrt{n})$
Distribución bajo H_0	cómo se reparte el estadístico **si H_0 es cierta**	t con $n - 1$ grados de libertad
Nivel de significancia α	el riesgo de rechazar H_0 siendo cierta que se acepta correr	0,05

En esta base cada prueba se escribe en **cinco pasos**, precedidos por los supuestos:

0. **Supuestos.** ¿Las observaciones son independientes? ¿La variable es normal, o la muestra es grande? ¿Hay datos extremos? Si un supuesto falla, el valor p no significa lo que dice.
1. **Pregunta en palabras.** «¿Los sacos vienen livianos?»
2. **Hipótesis.** H_0 y H_1 sobre el parámetro, con la cola elegida.
3. **Estadístico y su distribución bajo H_0.**
4. **Valor p o región de rechazo**, y la decisión con el α fijado antes.
5. **Conclusión en el lenguaje del problema.** No «se rechaza H_0» a secas, sino «hay evidencia de que los sacos pesan menos de 15 kg en promedio».

Cómo elegir H_1 y la cola

- **Lo que se quiere demostrar va en H_1.** H_0 es lo que se mantiene si no hay evidencia. Quien carga con la prueba decide qué va en cada lado: si el cliente acusa al proveedor de entregar sacos livianos, la acusación ($\mu < 15$) es H_1.
- **Una cola** ($H_1 : \mu < \mu_0$ o $H_1 : \mu > \mu_0$) cuando solo una dirección importa o lleva a una acción. **Dos colas** ($H_1 : \mu \neq \mu_0$) cuando cualquier desvío importa (un largo que no puede quedar ni corto ni largo).
- **La cola se elige antes de ver los datos.** Elegirla después, mirando hacia dónde salió la media, duplica en los hechos el riesgo de error tipo I.

Cuando H_1 es de una cola, H_0 puede escribirse como desigualdad ($\mu \geq 15$); la prueba se hace en el borde ($\mu = 15$), que es el caso más difícil de rechazar.

3. Región de rechazo y valor p · dos caminos, la misma decisión

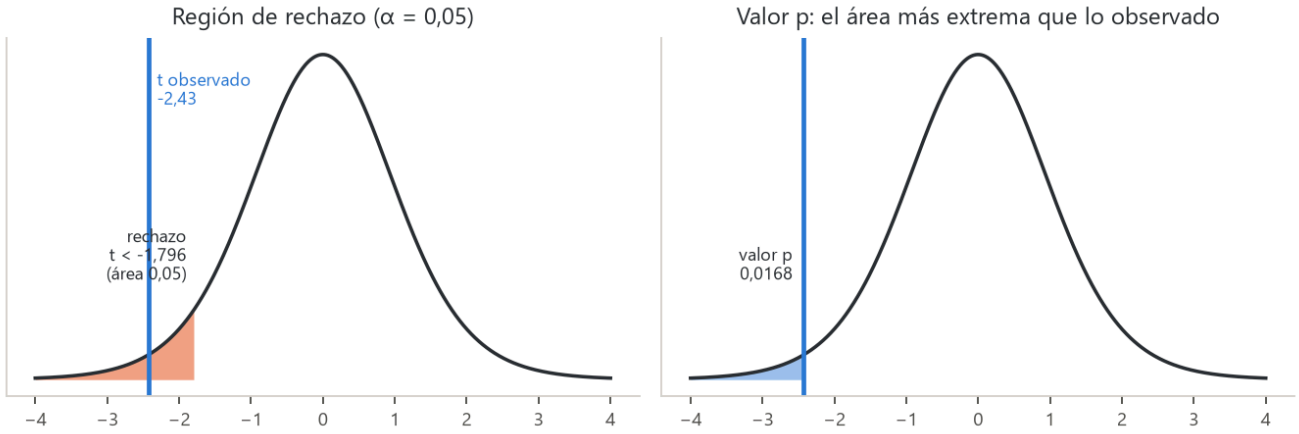
Región de rechazo. Se fija α y se buscan los valores del estadístico que, **si H_0 es cierta**, aparecerían con probabilidad α o menos. Si el estadístico cae ahí, se rechaza H_0.

H_1	Se rechaza H_0 si	Valor p
$\mu < \mu_0$ (cola izquierda)	$t \le -t_{1-\alpha,\,n-1}$	$P(T \le t)$
$\mu > \mu_0$ (cola derecha)	$t \ge t_{1-\alpha,\,n-1}$	$P(T \ge t)$
$\mu \neq \mu_0$ (dos colas)	$\lvert t\rvert \ge t_{1-\alpha/2,\,n-1}$	$2\,P(T \ge \lvert t\rvert)$

(Con σ conocida se cambia t por z y la t de Student por la normal estándar.)

Valor p. Es la probabilidad, **calculada suponiendo H_0 cierta**, de obtener un estadístico tan extremo o más que el observado, en la dirección de H_1. Mide qué tan sorprendentes son los datos para H_0: un valor p chico dice «si H_0 fuera cierta, esto casi nunca pasaría».

Por qué dan la misma decisión. La región de rechazo tiene área α. El valor p es el área desde el estadístico hacia afuera. El estadístico cae dentro de la región exactamente cuando su área hacia afuera es menor que la de la región: $p \le \alpha$ si y solo si el estadístico está en la región de rechazo. El valor p trae más información: dice para qué α se rechazaría, y el lector puede usar el suyo.



Lo que el valor p **no** es:

- No es la probabilidad de que H_0 sea cierta. Se calcula suponiéndola cierta.
- No es la probabilidad de que el resultado sea «por azar». Es la de ver algo así **si** solo hubiera azar.
- No mide el tamaño del efecto: con una muestra enorme, una diferencia irrelevante da p minúsculo.

Una escala de lectura habitual: $p < 0{,}01$, evidencia fuerte contra H_0; entre 0,01 y 0,05, evidencia moderada; entre 0,05 y 0,10, evidencia débil; sobre 0,10, los datos son compatibles con H_0. Compatible no es probado: **sobre 0,10 no se «acepta» H_0; no se rechaza.**

4. Los dos errores, la potencia y el tamaño de muestra

	H_0 es cierta	H_0 es falsa
Se rechaza H_0	error tipo I (probabilidad α)	decisión correcta (potencia $1-\beta$)
No se rechaza H_0	decisión correcta ($1-\alpha$)	error tipo II (probabilidad β)

- **Error tipo I:** una falsa alarma. Se detiene la línea, se reclama al proveedor o se lanza un producto «mejorado» que no lo era. Su probabilidad la fija quien diseña la prueba: es α.

- **Error tipo II:** un problema que pasa sin verse. Su probabilidad β no es una sola: depende de qué tan lejos de H_0 esté la verdad. Un desvío grande se detecta casi siempre; uno chico, casi nunca.
- **Potencia** $= 1 - \beta$: la probabilidad de detectar un desvío de un tamaño dado.

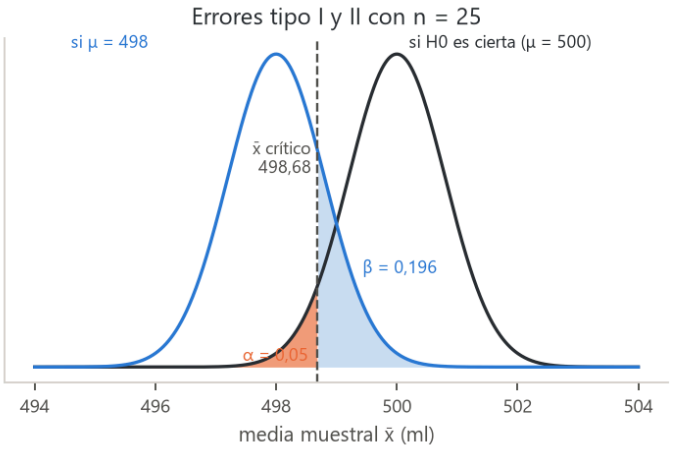
Elegir α es elegir qué error temer más. Bajar α (de 0,05 a 0,01) hace más difícil rechazar: hay menos falsas alarmas y más problemas que pasan. Con n fijo, α y β se mueven en sentido contrario. La única forma de bajar los dos es **más datos**. Si el error tipo II es el caro (un medicamento mal dosificado que llega al paciente), conviene un α más alto o una muestra más grande; si el caro es el tipo I (detener una planta sin motivo), un α más bajo.

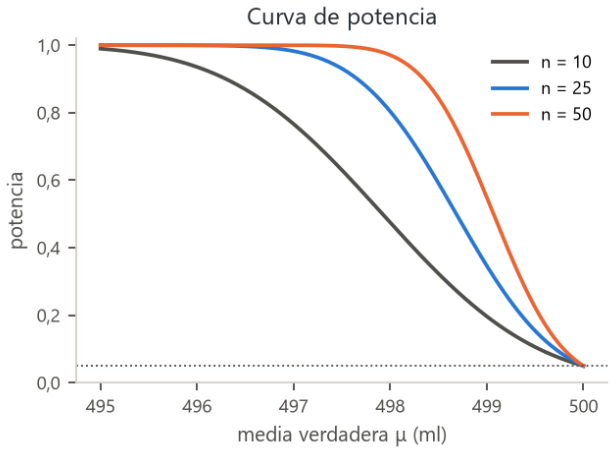
Potencia de la prueba z de una cola

Para $H_1 : \mu < \mu_0$ (o $\mu > \mu_0$), con σ conocida, si la media verdadera está a una distancia δ de μ_0:

$$1 - \beta = \Phi\left(\frac{|\delta|}{\sigma/\sqrt{n}} - z_{1-\alpha} \right)$$

La intuición. La prueba rechaza cuando $\bar{x}$ queda a más de $z_{1-\alpha}$ errores estándar de μ_0. Si la verdad está a $|\delta|/(\sigma/\sqrt{n})$ errores estándar, la pregunta es qué parte de la campana centrada en la verdad pasa esa línea. Más n angosta la campana; un δ mayor la aleja; los dos suben la potencia.





Tamaño de muestra

Despejando n para una potencia $1 - \beta$ deseada:

$$n = \left(\frac{(z_{1-\alpha} + z_{1-\beta})\,\sigma}{\delta} \right)^2 \qquad \text{(una cola; con dos colas se usa } z_{1-\alpha/2}\text{)}$$

Se redondea **hacia arriba**. El n crece con el cuadrado de σ/δ: detectar un desvío la mitad de grande cuesta cuatro veces más datos. Si σ se estima con s, el cálculo con la t (que hace `statsmodels`) pide unas pocas observaciones más.

---

5. Relación con el intervalo de confianza

Una prueba de dos colas con nivel α rechaza $H_0 : \mu = \mu_0$ **exactamente cuando μ_0 queda fuera del intervalo de confianza de nivel** $1 - \alpha$. Las dos herramientas usan la misma cuenta: el intervalo junta todos los μ_0 que la prueba no rechazaría.

$$\bar{x} \pm t_{1-\alpha/2,\,n-1}\,\frac{s}{\sqrt{n}}$$

Para una prueba de una cola el par es una **cota**: $H_1 : \mu < \mu_0$ se rechaza cuando μ_0 queda sobre la cota superior $\bar{x} + t_{1-\alpha,\,n-1}\,s/\sqrt{n}$.

El intervalo dice más que la decisión: muestra **qué tan grande puede ser el efecto**. Dos estudios pueden no rechazar H_0 y decir cosas muy distintas: uno con un intervalo angosto alrededor de μ_0 (no hay diferencia que importe) y otro con un intervalo ancho (no se sabe nada).

---

6. Las pruebas de esta unidad

Caso	Estadístico	Distribución bajo H_0	Cuándo
Media, σ conocida	$z = \dfrac{\bar{x} - \mu_0}{\sigma/\sqrt{n}}$	normal estándar	σ viene de mucha historia estable; variable normal o n grande
Media, σ desconocida	$t = \dfrac{\bar{x} - \mu_0}{s/\sqrt{n}}$	t con $n-1$ gl	lo habitual; variable aproximadamente normal
Proporción	$z = \dfrac{\hat{p} - p_0}{\sqrt{p_0(1-p_0)/n}}$	normal estándar (aproximada)	$np_0 \geq 10$ y $n(1-p_0) \geq 10$

Por qué la t y no la z con s. Usar s en vez de σ agrega una segunda fuente de azar: s también varía de muestra en muestra. La t de Student tiene colas más gruesas que la normal para compensarlo; con n grande las dos casi coinciden. Con n chico, usar z con s produce falsas alarmas de más.

Por qué p_0 y no $\hat{p}$ en la proporción. El estadístico se calcula **suponiendo H_0 cierta**, y bajo H_0 la varianza de $\hat{p}$ es $p_0(1-p_0)/n$. El intervalo de confianza, en cambio, usa $\hat{p}$, porque no supone ningún p_0.

Cuándo no aplican.

- **Datos dependientes** (mediciones seguidas de una máquina que deriva, la misma persona contada dos veces): el error estándar sale demasiado chico y el valor p, falsamente pequeño.
- **n chico y datos muy asimétricos o con un valor extremo:** la t deja de ser válida. Se mira un histograma o un gráfico Q–Q y una prueba de normalidad como Shapiro–Wilk (unidad 5); si falla, se usa una prueba no paramétrica o más datos.
- **Proporción con $np_0 < 10$:** la aproximación normal falla; se usa la binomial exacta (ejercicio 1.10).

7. Con Python

```
from scipy import stats
from statsmodels.stats.proportion import proportions_ztest
from statsmodels.stats.power import TTestPower

stats.ttest_1samp(x, popmean=15, alternative="less")     # t de una media ("two-sided",
"greater")
stats.shapiro(x)                                          # normalidad (H0: los datos son
normales)
stats.t.interval(0.95, len(x) - 1, loc=x.mean(), scale=stats.sem(x))   # IC 95 %
proportions_ztest(34, 420, value=0.06, alternative="larger", prop_var=0.06)  # proporción
con p0
stats.binomtest(7, 60, p=0.05, alternative="greater")     # proporción exacta
TTestPower().solve_power(effect_size=0.10 / s, alpha=0.05, power=0.90,
alternative="larger")  # n con la t
```

`alternative` fija la cola; `"less"` y `"greater"` se refieren a H_1. `prop_var=p0` hace que el error estándar use p_0, como la fórmula de la sección 6.

8. Ejemplo resuelto · ¿los sacos de pellets vienen livianos?

Una fábrica de pellets de madera de Los Ángeles vende sacos que dicen **15 kg**. Un distribuidor de Temuco sospecha que vienen livianos y pesa 12 sacos tomados al azar de un despacho. Los datos quedan en `datos/u01_pellets.csv` y el cuaderno `notebooks/u01_hipotesis.ipynb` reproduce todo.

Saco	x (kg)	$x - \bar{x}$	$(x - \bar{x})^2$
1	14,82	-0,1117	0,012469
2	15,05	0,1183	0,014003
3	14,91	-0,0217	0,000469
4	14,78	-0,1517	0,023003
5	15,02	0,0883	0,007803
6	14,95	0,0183	0,000336
7	14,87	-0,0617	0,003803
8	15,10	0,1683	0,028336
9	14,84	-0,0917	0,008403
10	14,96	0,0283	0,000803
11	14,89	-0,0417	0,001736
12	14,99	0,0583	0,003403

Paso 0 · Supuestos. Los sacos se tomaron al azar del despacho: se pueden tratar como independientes. Con $n = 12$ la t necesita una variable aproximadamente normal. Shapiro–Wilk da $W = 0{,}983$ con $p = 0{,}993$: nada contra la normalidad, y la tabla no muestra valores extremos.

Paso 1 · Pregunta. ¿El peso medio de los sacos es menor que 15 kg?

Paso 2 · Hipótesis. El distribuidor acusa; la acusación va en H_1:

$$H_0 : \mu = 15 \qquad H_1 : \mu < 15 \qquad \alpha = 0{,}05$$

Paso 3 · Estadístico. σ no se conoce: se usa t con $n - 1 = 11$ gl.

$$\bar{x} = \frac{179{,}18}{12} = 14{,}9317 \qquad s = \sqrt{\frac{0{,}1046}{11}} = 0{,}0975 \qquad \frac{s}{\sqrt{n}} = \frac{0{,}0975}{\sqrt{12}} = 0{,}0281$$

$$t = \frac{14{,}9317 - 15}{0{,}0281} = -2{,}43$$

Paso 4 · Región de rechazo y valor p. Cola izquierda: se rechaza si $t \le -t_{0{,}95;\,11} = -1{,}796$. El observado, $-2{,}43$, cae en la región. El valor p es $P(T_{11} \le -2{,}43) = 0{,}0168$, menor que 0,05: la misma decisión por los dos caminos. Con $\alpha = 0{,}01$ el valor crítico sería $-2{,}718$ y **no** se rechazaría.

Paso 5 · Conclusión. Con un 5 % de significancia, hay evidencia de que los sacos de ese despacho pesan en promedio menos de 15 kg.

Intervalo. El IC 95 % es $14{,}9317 \pm 2{,}201 \cdot 0{,}0281$, de **14,870 a 14,994 kg**. La cota superior de una cola (95 %) es $14{,}9317 + 1{,}796 \cdot 0{,}0281 = 14{,}982$ kg, bajo 15: calza con el rechazo. El faltante medio está entre unos 6 y 130 g por saco.

Potencia y tamaño de muestra. Al distribuidor le importa detectar sacos **100 g livianos** ($\delta = 0{,}10$). Tomando $\sigma \approx s = 0{,}0975$:

$$1 - \beta = \Phi\left(\frac{0{,}10}{0{,}0975/\sqrt{12}} - 1{,}645\right) = 0{,}972 \qquad n = \left(\frac{(1{,}645 + 1{,}282) \cdot 0{,}0975}{0{,}10}\right)^2 = 8{,}1$$

Doce sacos alcanzan de sobra: con 9 ya se llega a una potencia de 0,90 (con la t exacta, `statsmodels` pide 9,7, es decir 10). Pero si el distribuidor quisiera detectar un faltante de **50 g**, con 12 sacos la potencia baja a 0,552 y necesitaría 32,6, es decir 33 sacos: la mitad del desvío, cuatro veces la muestra.

```
x = pd.read_csv("datos/u01_pellets.csv").peso_kg
stats.ttest_1samp(x, 15, alternative="less")   # t = -2,43, p = 0,0168
```

Cómo se lee.

- La diferencia es estadísticamente clara al 5 %, pero no al 1 %. Si el distribuidor va a reclamar formalmente (y un error tipo I le costaría la relación con el proveedor), conviene pesar más sacos antes que forzar la conclusión.
- El tamaño importa más que el valor p: el faltante estimado es de 68 g por saco ($d = -0{,}70$ desviaciones). En un despacho de 2.000 sacos son unos 137 kg de pellets no entregados.
- La decisión práctica: pedir al proveedor que revise la calibración de la ensacadora y pesar 33 sacos en el próximo despacho, para poder ver también un faltante de 50 g.

9. Errores típicos

Error	Cómo evitarlo
«No se rechaza H_0, entonces H_0 es cierta» (o «se acepta H_0»)	No rechazar es falta de evidencia, no prueba. Mira el intervalo: si es ancho, no se sabe; solo un intervalo angosto alrededor de μ_0 dice «no hay diferencia que importe»
Leer el valor p como la probabilidad de que H_0 sea cierta	Es la probabilidad de datos así **suponiendo** H_0 cierta
Significativo = importante	Informa siempre el tamaño del efecto (la diferencia y su intervalo, o d). Con n enorme todo es significativo (ejercicio 1.8)
Elegir la cola o α después de ver los datos	Se fijan en el diseño. Cambiar a una cola porque «la media salió para ese lado» duplica el riesgo de error tipo I
Poner en H_0 lo que se quiere demostrar	Lo que se quiere mostrar va en H_1; H_0 lleva el signo igual
Usar z con s y n chico	Con σ desconocida, t con $n-1$ gl
En la proporción, usar $\hat{p}$ en el error estándar de la prueba, o la normal con $np_0 < 10$	La prueba usa p_0; con pocos esperados, binomial exacta
En dos colas, comparar p de una cola con α (o usar $z_{1-\alpha}$)	Dos colas: $p = 2P(T \geq \lvert t \rvert)$ y crítico $t_{1-\alpha/2}$
Mirar el valor p sin mirar los supuestos	Independencia, normalidad o n grande, datos extremos: un valor p con supuestos rotos no vale
Creer que β es un número fijo como α	β depende del desvío verdadero; se calcula para un desvío que importe

10. Práctica

Diez ejercicios: 1.1 a 1.4 básicos, 1.5 a 1.8 intermedios, 1.9 y 1.10 de desafío. Las pautas están en la sección 11. Resuélvelos a mano con tablas y confirma con `scipy`.

1.1 · Plantear antes de calcular (básico). Para cada situación escribe H_0 y H_1, di si es de una o dos colas y describe en palabras el error tipo I y el tipo II.

- (a) La Superintendencia fiscaliza que los cilindros de gas licuado de 11 kg no vengan con menos gas.
- (b) Un hospital cambia su protocolo de urgencias y quiere saber si cambió el tiempo medio de espera, que era de 42 minutos.
- (c) Un proveedor de cables asegura que a lo más el 2 % de los rollos viene con fallas; el comprador sospecha que son más.
- (d) Una minera quiere demostrar que un reactivo nuevo sube la recuperación media de cobre sobre el 88 % actual.

1.2 · Tableros con σ conocida (básico). Un aserradero de Mulchén corta tableros de un largo nominal de 2.440 mm. Por años de registros estables, $\sigma = 1{,}8$ mm. Se miden 40 tableros y $\bar{x} = 2.440{,}7$ mm. Con $\alpha = 0{,}05$, ¿el largo medio se corrió (en cualquier dirección)? Da z, el valor p, la decisión y el IC 95 %. ¿Y con $\alpha = 0{,}01$?

1.3 · Una cola o dos (básico). Un programa entrega $t = -1{,}94$ con 15 gl. (a) Calcula el valor p para $H_1 : \mu < \mu_0$ y para $H_1 : \mu \neq \mu_0$. (b) Decide en los cuatro casos ($\alpha = 0{,}05$ y 0,01, una y dos colas) por valor p y por valor crítico. (c) ¿Por qué el valor p de dos colas es el doble?

1.4 · Atrasos de reparto (básico). Una empresa de reparto de Concepción promete que a lo más el 6 % de los pedidos llega atrasado. En una muestra de 420 pedidos hubo 34 atrasados. Con $\alpha = 0{,}05$, ¿hay evidencia de que la tasa de atraso supera la promesa? Revisa primero la condición de la aproximación normal.

1.5 · Humedad de madera aserrada (intermedio). Un comprador exige que la humedad media de la madera seca no supere el 12 %. Mide 10 piezas de un lote (%):

1	2	3	4	5	6	7	8	9	10
12,4	11,8	12,9	12,6	12,1	13,0	11,9	12,7	12,3	12,5

(a) Revisa la normalidad. (b) Prueba si la humedad media supera el 12 % con $\alpha = 0{,}05$, por valor crítico y por valor p. (c) Calcula el IC 95 % y la cota inferior de una cola, y muestra que dicen lo mismo que la prueba. (d) Escribe la conclusión para el comprador.

1.6 · Potencia en una embotelladora (intermedio). Una embotelladora de agua mineral llena botellas de 500 ml con $\sigma = 4$ ml. El control toma 25 botellas y prueba $H_0 : \mu = 500$ contra $H_1 : \mu < 500$ con $\alpha = 0{,}05$. (a) ¿Bajo qué $\bar{x}$ se rechaza? (b) Si la media real es 498 ml, ¿cuál es β y cuál la potencia? (c) ¿Qué pasa con β si se usa $\alpha = 0{,}01$? (d) ¿Cuántas botellas hacen falta para detectar 498 ml con potencia 0,90 y $\alpha = 0{,}05$?

1.7 · Leer una prueba en un intervalo (intermedio). Un informe municipal dice: «el tiempo medio de atención en la oficina de patentes, con 36 trámites, tiene un IC 95 % de [18,4; 22,6] minutos» (calculado con z). (a) Sin calcular nada, ¿se rechazaría $H_0 : \mu = \mu_0$ (dos colas, 5 %) para μ_0 = 18, 20 y 23? (b) Recupera $\bar{x}$, el error estándar y s. (c) Calcula el estadístico y el valor p de las tres pruebas y confirma (a). (d) ¿Se rechazaría $\mu_0 = 18$ al 1 %?

1.8 · Significativo no es importante (intermedio). (a) Una aplicación de reparto analiza 40.000 pedidos: el tiempo medio fue de 31,2 minutos con $s = 12$, contra los 31,0 del año anterior. Prueba $H_0 : \mu = 31$ (dos colas, 5 %) y calcula el efecto en segundos y en desviaciones (d). (b) Un piloto de una ruta nueva en 6 trayectos ahorró en promedio 4,1 minutos, con $s = 5{,}3$. Prueba si el ahorro medio es mayor que cero (5 %) y calcula d. (c) ¿Cuál de los dos resultados importa más para el negocio y qué harías con cada uno?

1.9 · Elegir α con costos (desafío). Una planta de prefabricados recibe lotes de cemento. Un lote conforme da una resistencia media de 250 (en las unidades del ensayo); uno malo, de 240. La desviación de un ensayo es $\sigma = 12$ y se ensayan $n = 9$ probetas por lote. Se prueba $H_0 : \mu = 250$ contra $H_1 : \mu < 250$. Rechazar un lote bueno cuesta \$800.000 (flete y atraso); aceptar uno malo cuesta \$5.000.000 (refuerzo y reparación). Históricamente, el 25 % de los lotes es malo. (a) Para α = 0,01, 0,05, 0,10 y 0,20, calcula el $\bar{x}$ crítico, β y el costo esperado por lote, $0{,}75\,\alpha \cdot 800.000 + 0{,}25\,\beta \cdot 5.000.000$. (b) ¿Qué α conviene? (c) Busca numéricamente el α que minimiza el costo. ¿Por qué no es 0,05?

1.10 · Burbujas en botellas, con pocos datos (desafío). Una vidriería promete a lo más un 5 % de botellas con burbujas. Una inspección encontró 7 en 60. (a) ¿Se cumple la condición de la aproximación normal? (b) Calcula el valor p con z y el exacto con la binomial ($H_1 : p > 0{,}05$). ¿Cambia la decisión al 1 %? (c) Con 60

botellas y la prueba exacta al 5 %, ¿desde cuántas botellas con burbujas se rechaza, cuál es el α real y qué potencia tiene si la tasa verdadera es 12 %? (d) ¿Cuántas botellas hacen falta para detectar un 12 % con potencia 0,80 ($\alpha = 0{,}05$, una cola)? Usa

$$n = \left(\frac{z_{1-\alpha}\sqrt{p_0(1-p_0)} + z_{1-\beta}\sqrt{p_1(1-p_1)}}{p_1 - p_0} \right)^2$$

11. Pautas

1.1.

	H_0	H_1	Colas	Error tipo I	Error tipo II
(a)	$\mu = 11$ kg	$\mu < 11$ kg	una (izquierda)	multar a una distribuidora que cumple	dejar pasar cilindros con menos gas
(b)	$\mu = 42$ min	$\mu \neq 42$ min	dos	creer que el protocolo cambió la espera sin que la cambiara	no ver un cambio real (para bien o para mal)
(c)	$p = 0{,}02$	$p > 0{,}02$	una (derecha)	reclamar a un proveedor que cumple	aceptar rollos fallados de más
(d)	$\mu = 88\ \%$	$\mu > 88\ \%$	una (derecha)	adoptar un reactivo que no mejora	descartar un reactivo que sí mejora

En (a), (c) y (d) lo que se quiere mostrar (la falta, el exceso, la mejora) va en H_1. En (b) el hospital no sabe hacia dónde se movió la espera: dos colas.

1.2. $\sigma/\sqrt{n} = 1{,}8/\sqrt{40} = 0{,}2846$ mm y $z = 0{,}7/0{,}2846 = 2{,}46$. Dos colas: $p = 2P(Z \geq 2{,}46) = 0{,}0139$. Al 5 % se rechaza ($|z| > 1{,}96$): el largo medio se corrió hacia arriba. El IC 95 % es de **2.440,14 a 2.441,26 mm**, que no contiene 2.440. Al 1 % no se rechaza ($0{,}0139 > 0{,}01$; $2{,}46 < 2{,}576$). Lectura: el corrimiento es real con bastante seguridad, pero chico (menos de un milímetro y medio en el peor caso); antes de parar la sierra conviene saber si 0,7 mm le importan al cliente.

1.3. (a) $P(T_{15} \leq -1{,}94) = 0{,}0357$ para la cola izquierda y $2 \cdot 0{,}0357 = 0{,}0714$ para dos colas. (b)

	$\alpha = 0{,}05$	$\alpha = 0{,}01$
Una cola (crítico $-t_{1-\alpha}$)	$-1{,}753$: **se rechaza** ($p = 0{,}0357$)	$-2{,}602$: no se rechaza
Dos colas (crítico $\pm t_{1-\alpha/2}$)	$\pm 2{,}131$: no se rechaza ($p = 0{,}0714$)	$\pm 2{,}947$: no se rechaza

(c) Con dos colas, un valor tan extremo como $-1{,}94$ cuenta también si sale hacia el otro lado ($+1{,}94$); la t es simétrica, así que el área se duplica. Por eso el mismo dato rechaza con una cola y no con dos: la cola única es más potente, pero solo si se eligió antes de ver los datos.

1.4. $np_0 = 420 \cdot 0{,}06 = 25{,}2$ y $n(1-p_0) = 394{,}8$: la aproximación vale. $\hat{p} = 34/420 = 0{,}0810$; el error estándar bajo H_0 es $\sqrt{0{,}06 \cdot 0{,}94/420} = 0{,}01159$ y $z = (0{,}0810 - 0{,}06)/0{,}01159 = 1{,}81$, sobre el crítico 1,645. $p = 0{,}0353 < 0{,}05$: hay evidencia de que los atrasos superan el 6 % prometido. Al 1 % no alcanzaría. Lectura: la empresa promete algo que, con estos datos, no cumple; o mejora el reparto o ajusta la promesa.

1.5. (a) Shapiro–Wilk da $p = 0{,}867$: nada contra la normalidad. (b) $H_0 : \mu = 12$ contra $H_1 : \mu > 12$. $\bar{x} = 12{,}42$, $s = 0{,}4022$, $s/\sqrt{10} = 0{,}1272$ y $t = 0{,}42/0{,}1272 = 3{,}30$ con 9 gl. El crítico es $t_{0{,}95;\,9} = 1{,}833$: se rechaza. Valor $p = 0{,}0046$. (c) IC 95 %: $12{,}42 \pm 2{,}262 \cdot 0{,}1272$, de **12,13 a 12,71 %**. La cota inferior de una cola es $12{,}42 - 1{,}833 \cdot 0{,}1272 = 12{,}19$ %: todo el rango plausible queda sobre 12 %, igual que la prueba. (d) «La humedad media del lote supera el 12 % exigido; lo más probable es que esté entre 12,2 y 12,7 %. El lote necesita más secado antes de aceptarse.»

1.6. El error estándar es $4/\sqrt{25} = 0{,}8$ ml. (a) Se rechaza si $\bar{x} < 500 - 1{,}645 \cdot 0{,}8 = 498{,}68$ ml. (b) Si $\mu = 498$, $\beta = P(\bar{x} \ge 498{,}68) = P(Z \ge 0{,}855) = 0{,}196$; $la potencia es **0,804**. (c) Con $\alpha = 0{,}01$ el crítico baja a 498,14 y β sube a **0,431**: se compra menos falsa alarma con más botellas cortas sin detectar. (d) $n = ((1{,}645 + 1{,}282) \cdot 4/2)^2 = 34{,}26$, así que $n = 35$ botellas, con potencia 0,905. Lectura: la muestra de 25 se pierde una de cada cinco veces un llenado 2 ml corto; 35 botellas lo bajan a una de cada diez.

1.7. (a) Sin calcular: 18 y 23 quedan fuera del intervalo (se rechazan); 20 queda dentro (no se rechaza). (b) $\bar{x} = (18{,}4 + 22{,}6)/2 = 20{,}50$; el semiancho 2,1 es $1{,}96$ errores estándar, así que $s/\sqrt{n} = 2{,}1/1{,}96 = 1{,}0714$ y $s = 1{,}0714 \cdot 6 = 6{,}43$ min. (c)

μ_0	z	p (dos colas)	Decisión al 5 %
18	2,33	0,0196	se rechaza
20	0,47	0,6407	no se rechaza
23	-2,33	0,0196	se rechaza

(d) El IC 99 % es $20{,}50 \pm 2{,}576 \cdot 1{,}0714$, de **17,74 a 23,26**: contiene 18, así que al 1 % no se rechaza ($p = 0{,}0196 > 0{,}01$). Lectura: un intervalo es una prueba hecha para todos los μ_0 a la vez.

1.8. (a) Error estándar $12/\sqrt{40.000} = 0{,}060$ y $z = 0{,}2/0{,}060 = 3{,}33$, $p < 0{,}001$: muy significativo. Pero el efecto es de 12 segundos por pedido, $d = 0{,}2/12 = 0{,}017$ desviaciones: irrelevante para un cliente. (b) $s/\sqrt{6} = 2{,}164$ y $t = 4{,}1/2{,}164 = 1{,}89$ con 5 gl, $p = 0{,}0583$: no significativo al 5 %. Pero $d = 4{,}1/5{,}3 = 0{,}77$: un efecto grande. (c) El que importa es el piloto: un ahorro de cuatro minutos por trayecto vale la pena, y no se rechaza solo porque 6 trayectos son pocos. La decisión no es «no sirve», sino ampliar el piloto. El resultado (a) no justifica ninguna acción, por bajo que sea su valor p.

1.9. Error estándar $12/\sqrt{9} = 4$. Para cada α: $\bar{x}$ crítico $= 250 - z_{1-\alpha} \cdot 4$ y $\beta = 1 - \Phi(10/4 - z_{1-\alpha})$.

α	$\bar{x}$ crítico	β	Costo tipo I	Costo tipo II	Costo esperado
0,01	240,69	0,4311	$6.000	$538.837	$544.837
0,05	243,42	0,1962	$30.000	$245.294	$275.294
0,10	244,87	0,1115	$60.000	$139.409	$199.409
0,20	246,63	0,0486	$120.000	$60.776	$180.776

(b) De los cuatro, conviene $\alpha = 0{,}20$. (c) El mínimo está en $\alpha = 0{,}169$, con $\beta = 0{,}061$ y un costo de $178.339 por lote. No es 0,05 porque aceptar un lote malo cuesta más de seis veces lo que cuesta rechazar uno bueno: la planta debe tolerar más falsas alarmas para que se le escapen menos lotes malos. El 0,05 es

una costumbre, no una ley; cuando los costos se conocen, mandan ellos. (Y si los dos errores son caros, la salida es ensayar más probetas.)

1.10. (a) $np_0 = 60 \cdot 0{,}05 = 3{,}0$, muy bajo 10: la normal no sirve. (b) $\hat{p} = 7/60 = 0{,}1167$, $z = 2{,}37$ y $p = 0{,}0089$ con la normal; la binomial exacta da $P(X \geq 7) = 0{,}0297$. Con z se rechazaría al 1 %; con la exacta, no. La normal exagera la evidencia porque la binomial con $np_0 = 3$ es muy asimétrica. (c) Se rechaza con **7 o más** botellas con burbujas ($P(X \geq 7) = 0{,}0297 \leq 0{,}05$, y con 6 ya pasaría de 0,05); el α real es 0,0297, no 0,05, porque la binomial va a saltos. Si la tasa verdadera es 12 %, la potencia es solo **0,591**. (d) $n = \big((1{,}645 \cdot 0{,}218 + 0{,}842 \cdot 0{,}325)/0{,}07\big)^2 = 81{,}5$: hacen falta **82 botellas**. Lectura: con 60 botellas la vidriería tiene evidencia moderada de incumplir; para un reclamo firme, 82 botellas o más.

---

12. Caso integrador · Estampa Sur, ¿el pulpo 6 cumple la meta de registro?

> Estampa Sur es el taller de estampado que recorre la base. Sus datos son **simulados** con semilla fija por `verificacion/caso_estampa_sur_datos.py` y quedan en `datos/`; no describen ningún taller real. Esta es la primera pieza del caso en este ramo.

El **registro** es el calce entre los colores de un estampado: se mide el desplazamiento de un color respecto de su posición correcta, en mm. El taller se fijó como meta que el desplazamiento medio de cada máquina («pulpo») no supere **0,10 mm**. En `datos/registro.csv` hay 18 prendas medidas en el pulpo 6 y 22 en el pulpo 4. Las del pulpo 6:

1	2	3	4	5	6	7	8	9
0,021	0,113	0,090	0,066	0,012	0,143	0,081	0,123	0,141

10	11	12	13	14	15	16	17	18
0,124	0,104	0,139	0,133	0,137	0,044	0,096	0,084	0,232

Paso 0 · Supuestos. Prendas de distintas tandas: independientes. Shapiro–Wilk da $W = 0{,}944$ y $p = 0{,}344$; la prenda 18 (0,232) es la más alta, pero no rompe la normalidad.

Paso 1 · Pregunta. ¿El desplazamiento medio del pulpo 6 supera la meta?

Paso 2 · Hipótesis. El jefe de taller solo actúa si hay evidencia de incumplimiento:

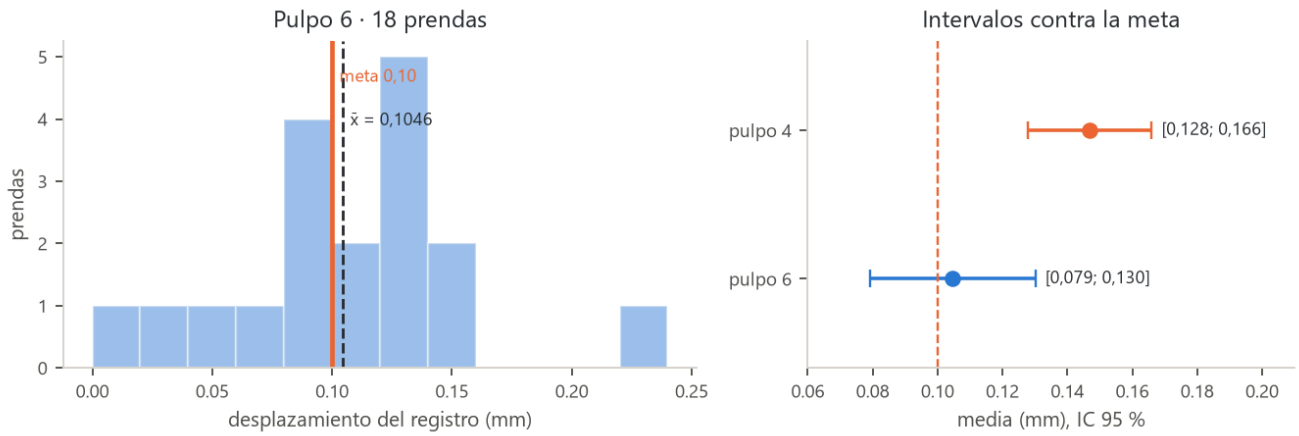
$$H_0 : \mu = 0{,}10 \qquad H_1 : \mu > 0{,}10 \qquad \alpha = 0{,}05$$

Paso 3 · Estadístico. $\bar{x} = 1{,}883/18 = 0{,}1046$ mm, $s = 0{,}0514$ mm y $s/\sqrt{18} = 0{,}0121$. Con 17 gl:

$$t = \frac{0{,}1046 - 0{,}10}{0{,}0121} = 0{,}38$$

Paso 4 · Decisión. El crítico es $t_{0{,}95;\,17} = 1{,}740$ (equivale a $\bar{x} > 0{,}1211$ mm). El observado está lejos: $p = 0{,}354$. No se rechaza.

Paso 5 · Conclusión. Con estos datos **no hay evidencia de que el pulpo 6 supere la meta**. Eso no es lo mismo que decir que la cumple: el IC 95 % de la media va de **0,079 a 0,130 mm**, y la meta queda casi al centro. El pulpo 6 podría estar 0,02 mm bajo la meta o 0,03 mm sobre ella.



¿Alcanzan 18 prendas? Si el pulpo 6 estuviera en realidad en 0,13 mm (0,03 sobre la meta), con 18 prendas la prueba lo detectaría con potencia de 0,80 (tomando $\sigma \approx s$): $n = ((1{,}645 + 0{,}842) \cdot 0{,}0514/0{,}03)^2 = 18{,}1$. Para ver un exceso de 0,02 mm harían falta 40,8, es decir 41 prendas. El estudio era capaz de ver un incumplimiento grande, no uno chico.

El pulpo 4. La misma prueba con sus 22 prendas: $\bar{x} = 0{,}1470$ mm, $s = 0{,}0429$, $t = 5{,}13$ con 21 gl y $p < 0{,}001$; su IC 95 % va de 0,128 a 0,166 mm, entero sobre la meta. El pulpo 4 **sí** incumple.

```
reg = pd.read_csv("datos/registro.csv")
a = reg[reg.maquina == "pulpo 6"].desplazamiento_mm
stats.ttest_1samp(a, 0.10, alternative="greater")   # t = 0,38, p = 0,354
```

Lectura. El pulpo 4 hay que revisarlo ya (tensión de malla, topes de la paleta). El pulpo 6 queda en observación: medir 41 prendas antes de darlo por bueno. Y aparece la pregunta de la próxima unidad: el pulpo 4 desplaza más que la meta, pero ¿desplaza más **que el pulpo 6**? Comparar cada máquina con 0,10 no responde eso; hace falta comparar las dos medias entre sí (unidad 2) y, después, sus variabilidades (unidad 3).

---

13. Para seguir

En los libros del ramo. Para esta unidad el programa remite a Walpole, Myers, Myers y Ye, *Probabilidad y estadística para ingeniería y ciencias* (edición en español de 2012), capítulo 9, y a Casella y Berger, *Statistical Inference*, capítulo 8 (pruebas de hipótesis y su construcción por razón de verosimilitudes, para quien quiera ver de dónde salen estas pruebas).

Abiertos y gratis.

- Diez, Çetinkaya-Rundel y Barr, *OpenIntro Statistics* (en inglés), capítulo 5 «Foundations for Inference» y capítulo 6 para una proporción. PDF gratis en https://www.openintro.org/book/os/
- NIST/SEMATECH, *e-Handbook of Statistical Methods*, sección 7.2 «Comparisons based on data from one process» (en inglés), con tamaños de muestra para una media y una proporción: https://www.itl.nist.gov/div898/handbook/prc/section2/prc2.htm

Con el tutor. La carpeta `tutor/` trae el contexto de este ramo. Pégalo al inicio de la conversación con cualquier IA y pídele, por ejemplo: «Dame una situación de planta, sin decirme la cola, y corrígeme las hipótesis, el valor p y la conclusión en los cinco pasos».