Unidad 5 · Bondad de ajuste y normalidad

Qué vas a poder hacer. Proponer una distribución para unos datos y contrastarla: armar clases y frecuencias esperadas para una prueba chi-cuadrado y descontar los parámetros estimados de los grados de libertad; calcular a mano el estadístico de Kolmogorov-Smirnov y saber cuándo su tabla deja de valer; usar Anderson-Darling y Shapiro-Wilk con Python, y leer un gráfico Q-Q antes de creerle a cualquier valor p.

Lo que necesitas antes. De la unidad 1, los cinco pasos de una prueba y qué significa un valor p. De la unidad 4, el estadístico chi-cuadrado $\sum(o-e)^2/e$ y la regla de las esperadas mayores o iguales a 5. De Probabilidades: las distribuciones de Poisson, binomial, exponencial y normal, y qué es una función de distribución acumulada $F(x) = P(X \le x)$.

Tiempo. Unas 6 horas: 2,5 de lectura con el ejemplo y el cuaderno, 3,5 de práctica.

1. La idea · ¿estos datos vienen de esa distribución?

Casi todo lo que viene en el ramo supone algo sobre la forma de los datos. Una prueba t supone normalidad; un modelo de colas supone llegadas de Poisson y tiempos exponenciales; una simulación de inventario necesita una distribución para la demanda. Si el supuesto es falso, el resultado puede ser falso aunque la cuenta esté bien hecha.

Una **prueba de bondad de ajuste** contrasta:

$$H_0 : \text{los datos vienen de la distribución } F_0 \qquad H_1 : \text{no vienen de } F_0$$

Fíjate en la dirección. Acá H_0 es lo que **quieres** que sea cierto (que el modelo sirva), y la prueba solo puede juntar evidencia en su contra. Por eso:

> **«No se rechaza» no es «se demuestra».** Un valor p grande dice que los datos no contradicen a F_0, no que F_0 sea la verdadera. Con pocos datos, casi ninguna distribución se rechaza. La frase correcta es «el modelo es compatible con los datos», nunca «los datos son normales».

Hay tres familias de herramientas, y se usan juntas:

Herramienta	Qué compara	Sirve para
Chi-cuadrado	conteos por clase, observados contra esperados	datos discretos o agrupados en clases
Kolmogorov-Smirnov y Anderson-Darling	la distribución acumulada de los datos contra F_0	datos continuos, sin agrupar
Shapiro-Wilk y gráfico Q-Q	los datos ordenados contra los cuantiles de la normal (o de otra F_0)	normalidad, y ver **cómo** falla el ajuste

2. Chi-cuadrado de bondad de ajuste

Cómo se arma

1. **Clases.** Se divide el recorrido en k clases que no se traslapan y que cubren todo (la última suele ser «c o más»). En datos discretos las clases son los valores; en continuos, intervalos.
2. **Probabilidad de cada clase bajo H_0:** $p_i = P(X \in \text{clase } i)$, con la F_0 propuesta.
3. **Frecuencia esperada:** $e_i = n\,p_i$.
4. **Agrupar** las clases con $e_i < 5$ con sus vecinas, hasta que todas cumplan. Se agrupa mirando las **esperadas**, no las observadas.
5. **Estadístico:**

$$\chi^2 = \sum_{i=1}^{k} \frac{(o_i - e_i)^2}{e_i} \;\sim\; \chi^2_{k-1-m} \text{ bajo } H_0$$

donde k es el número de clases **después de agrupar** y m el número de parámetros que se estimaron con los mismos datos.

Por qué los grados de libertad son $k - 1 - m$

Los k conteos no son libres: suman n, así que basta conocer $k - 1$. Eso explica el -1. Cada parámetro estimado con los datos (una media para la Poisson, media y desviación para la normal) obliga a la distribución ajustada a pasar más cerca de los datos, y gasta otro grado de libertad.

Distribución propuesta	Parámetros que suelen estimarse	m
uniforme discreta, dado, binomial con p dado	ninguno	0
Poisson	$\lambda = \bar{x}$	1
binomial con n conocido	$p = \bar{x}/n$	1
exponencial	la media	1
normal	μ y σ	2

Si un parámetro viene **de afuera** (una norma, un historial, el fabricante), no se descuenta.

La intuición. Cada término $(o_i - e_i)^2/e_i$ mide la sorpresa en una clase, escalada por lo que se esperaba: 5 intervalos de más pesan mucho si se esperaban 4 y poco si se esperaban 400. Por eso, además del total, conviene mirar **qué clase aporta más**: dice dónde falla el modelo.

Cuándo no aplica. Con esperadas chicas la aproximación chi-cuadrado falla (de ahí la regla del 5). En datos continuos funciona, pero agrupar bota información y el resultado depende de dónde se pongan los cortes: si se puede, se usa KS o Anderson-Darling.

3. Kolmogorov-Smirnov

La distribución empírica

Con n datos ordenados $x_{(1)} \le \cdots \le x_{(n)}$, la **función de distribución empírica** es la fracción de datos que no supera x:

$$F_n(x) = \frac{\#\{x_i \le x\}}{n}$$

Es una escalera que sube $1/n$ en cada dato. Si H_0 es cierta, la escalera debería pegarse a la curva F_0.

El estadístico

$$D = \sup_x |F_n(x) - F_0(x)|$$

es la mayor distancia **vertical** entre la escalera y la curva. Como la escalera salta en cada dato, la mayor distancia ocurre justo antes o justo después de un salto. Para cada dato ordenado se calculan dos diferencias:

$$D_i^+ = \frac{i}{n} - F_0(x_{(i)}) \qquad D_i^- = F_0(x_{(i)}) - \frac{i-1}{n} \qquad D = \max_i \left(D_i^+,\, D_i^-\right)$$

D^+ mira la parte alta del escalón; D^-, la parte baja. Calcular solo $|i/n - F_0|$ es un error frecuente: subestima D.

Región de rechazo: se rechaza si $D > D_{n,\alpha}$, el valor de la tabla de Kolmogorov-Smirnov. Para $n > 40$, $D_{n;0{,}05} \approx 1{,}36/\sqrt{n}$. El valor p lo da `scipy.stats.kstest`.

La intuición. Bajo H_0, la distribución de D **no depende de cuál sea** F_0 (si es continua y está completamente especificada): al transformar cada dato con $u = F_0(x)$, cualquier continua se vuelve uniforme entre 0 y 1. Por eso una sola tabla sirve para la normal, la exponencial o la que sea.

Supuestos

- F_0 es **continua** (para conteos se usa chi-cuadrado).
- F_0 está **completamente especificada** antes de mirar los datos: sus parámetros vienen de afuera. Este supuesto es el que más se rompe, y merece su propia sección.

---

4. Estimar los parámetros cambia la distribución del estadístico

Supón que quieres probar normalidad y no conoces μ ni σ. Lo natural es usar $\bar{x}$ y s de la muestra y aplicar KS. El problema: la normal con $\bar{x}$ y s **se ajustó a esos mismos datos**, así que queda más cerca de la escalera de lo que quedaría la verdadera. D sale más chico de lo que la tabla espera, y la tabla de KS (hecha para F_0 fija) da valores críticos demasiado grandes.

Resultado: la prueba casi nunca rechaza. El nivel nominal es 5 %, pero el real es mucho menor, y la prueba pierde potencia. El ejercicio 5.10 lo mide por simulación.

La corrección. Lilliefors calculó por simulación los valores críticos cuando se estiman los parámetros de una normal (y después de una exponencial). Para la normal y $n > 30$, al 5 %:

$$D_{\text{crítico}} \approx \frac{0{,}886}{\sqrt{n}} \quad \text{en vez de} \quad \frac{1{,}36}{\sqrt{n}}$$

En Python: `statsmodels.stats.diagnostic.lilliefors(x, dist="norm")` o `dist="exp"`. El estadístico es el mismo D; cambia el valor p.

> La misma idea vale para la chi-cuadrado (el $-m$ de los grados de libertad) y para Anderson-Darling (sus valores críticos cambian según qué se estimó). **Siempre que un parámetro sale de los datos, la distribución del estadístico cambia.**

---

5. Anderson-Darling

KS mira **una** distancia, la mayor, y es poco sensible en las colas: allí F_0 está cerca de 0 o de 1 y las diferencias son chicas en valor absoluto aunque sean grandes en proporción. Anderson-Darling suma todas las diferencias al cuadrado y les da más peso donde $F_0(1-F_0)$ es chico, o sea, en las colas:

$$A^2 = n \int \frac{(F_n(x) - F_0(x))^2}{F_0(x)\,(1 - F_0(x))}\, dF_0(x)$$

Con los datos ordenados y $F_i = F_0(x_{(i)})$, la integral se calcula así:

$$A^2 = -n - \frac{1}{n}\sum_{i=1}^{n}(2i-1)\,[\ln F_i + \ln(1 - F_{n+1-i})]$$

Se rechaza si A^2 supera el valor crítico. Con F_0 completamente especificada, al 5 % es 2,492 (sirve desde $n = 5$). Si se estiman parámetros, el valor crítico depende de la distribución y de qué se estimó; `scipy.stats.anderson(x, dist="norm")` o `dist="expon"` los trae ya corregidos.

Cuándo preferirla. Cuando importan las colas: tiempos de espera largos, demandas extremas, cargas máximas. Es más potente que KS en casi todas las alternativas.

---

6. Shapiro-Wilk · la prueba de normalidad

Shapiro-Wilk sirve solo para la normal y es, en general, la más potente para ese caso. Su estadístico es

$$W = \frac{\left(\sum_{i=1}^{n} a_i\, x_{(i)}\right)^2}{\sum_{i=1}^{n}(x_i - \bar{x})^2}$$

donde los a_i salen de los valores esperados de los datos ordenados de una normal estándar. **La intuición:** W es, casi, el cuadrado de la correlación entre los datos ordenados y los cuantiles normales; es decir, mide qué tan recto es el gráfico Q-Q. W cerca de 1 es compatible con normalidad; W chico, no.

Los cinco pasos son los de siempre: H_0: normal, H_1: no normal, W con su distribución tabulada (la da `scipy.stats.shapiro`), valor p, conclusión. No hay que estimar nada aparte: la prueba ya considera que μ y σ son desconocidas.

Dos advertencias de tamaño.

- **Con pocos datos** (menos de 15 o 20) casi nada se rechaza: la prueba no tiene potencia. Un p grande con $n = 8$ no dice mucho.
- **Con muchos datos** (miles) se rechaza por desviaciones mínimas, sin importancia práctica. Una prueba t o un ANOVA toleran bien desvíos leves de normalidad con n grande.

En los dos casos manda el gráfico Q-Q.

7. El gráfico Q-Q

Se ordenan los datos y se grafica cada $x_{(i)}$ contra el cuantil que F_0 predice para su posición:

$$q_i = F_0^{-1}(p_i) \qquad p_i = \frac{i - 0{,}5}{n} \quad \text{o bien} \quad p_i = \frac{i - 0{,}375}{n + 0{,}25} \ \text{(Blom)}$$

Las dos posiciones son convenciones; Blom es la que usa la normal en muchos programas. Si F_0 describe bien los datos, los puntos caen sobre una recta. Para la normal estándar se grafica $x_{(i)}$ contra z_i y la recta tiene pendiente s y corte $\bar{x}$.

Lo que se ve	Qué significa
puntos sobre la recta	el modelo es razonable
curva cóncava hacia arriba (los puntos de la derecha suben por encima)	asimetría a la derecha: tiempos, montos, ingresos
forma de S, con las dos puntas alejándose de la recta	colas más pesadas que la normal
S invertida, puntas hacia la recta	colas más livianas (datos acotados, casi uniformes)
un punto suelto en un extremo	un posible atípico: revisarlo antes de concluir
escalones horizontales	datos redondeados o discretos

El Q-Q no da un valor p, pero dice **cómo** falla el ajuste, y eso decide qué hacer: transformar (logaritmo para la asimetría), cambiar de modelo (exponencial, lognormal) o usar un método que no suponga normalidad.

8. Qué prueba usar

Situación	Prueba
Conteos (Poisson, binomial, geométrica) o datos ya agrupados	chi-cuadrado, con $k - 1 - m$ grados de libertad
Continua, F_0 completamente especificada	KS o Anderson-Darling
Continua, parámetros estimados de los datos	Lilliefors (KS corregido) o Anderson-Darling con sus valores críticos corregidos
Normalidad, con μ y σ desconocidas	Shapiro-Wilk, siempre con el Q-Q al lado
Supuesto de normalidad de un ANOVA o una regresión	Shapiro-Wilk y Q-Q **de los residuos**, no de la variable cruda (unidades 7, 9 y 10)

Supuestos comunes a todas: observaciones independientes (si los datos son una serie de tiempo con inercia, ninguna de estas tablas vale) y una sola población (dos turnos con medias distintas mezclados no siguen ninguna distribución simple).

9. Ejemplo resuelto · las llamadas de una pizzería

Una pizzería de Talca quiere decidir cuántas personas atienden el teléfono los viernes en la noche. Para modelar la carga necesita saber cómo llegan las llamadas.

Parte A · ¿El número de llamadas por intervalo sigue una Poisson?

Registró las llamadas en 120 intervalos de 15 minutos (los viernes de un mes):

Llamadas en 15 min	0	1	2	3	4	5	6
Intervalos	27	36	30	17	6	3	1

Paso 1 · La pregunta. ¿Las llamadas llegan al azar y de forma pareja en el tiempo, como predice una Poisson?

Supuestos. Intervalos independientes entre sí; una sola tasa (todos los intervalos son de la misma franja, viernes de 20 a 23 h).

Paso 2 · Hipótesis. H_0: el número de llamadas por intervalo sigue una Poisson. H_1: no la sigue. La tasa no se conoce: se estima.

$$\hat{\lambda} = \bar{x} = \frac{0\cdot 27 + 1\cdot 36 + 2\cdot 30 + 3\cdot 17 + 4\cdot 6 + 5\cdot 3 + 6\cdot 1}{120} = \frac{192}{120} = 1{,}60$$

Paso 3 · Esperadas y estadístico. Con $P(X=k) = e^{-1{,}6}\,1{,}6^k/k!$ y $e_k = 120\,P(X=k)$, las esperadas de 4 y de «5 o más» son 6,62 y 2,84. La segunda es menor que 5: se agrupan las tres últimas clases en «4 o más» ($o = 6+3+1 = 10$).

Clase	o_i	e_i	$(o_i - e_i)^2/e_i$
0	27	24,23	0,317
1	36	38,76	0,197
2	30	31,01	0,033
3	17	16,54	0,013
4 o más	10	9,46	0,031
Total	120	120,00	**0,591**

Quedan $k = 5$ clases y se estimó un parámetro: $gl = 5 - 1 - 1 = 3$.

Paso 4 · Valor p y región de rechazo. $\chi^2_{0{,}95;\,3} = 7{,}815$. Como $0{,}591 < 7{,}815$, no se rechaza; el valor p es p = 0,898.

Paso 5 · Conclusión. El conteo de llamadas es compatible con una Poisson de 1,6 llamadas cada 15 minutos. Si la llegada es Poisson, el tiempo entre llamadas es exponencial con media $15/1{,}6 = 9{,}38$ minutos. Eso se contrasta en la parte B.

Parte B · ¿Los tiempos entre llamadas son exponenciales de media 9 minutos?

La central telefónica informa que, en su historial anual, el promedio entre llamadas del viernes es de **9 minutos**. La pizzería midió 10 tiempos seguidos (minutos), ya ordenados: 2,1; 3,4; 4,8; 6,0; 7,7; 9,5; 12,3; 15,0; 19,6; 26,2. Su media es 10,66.

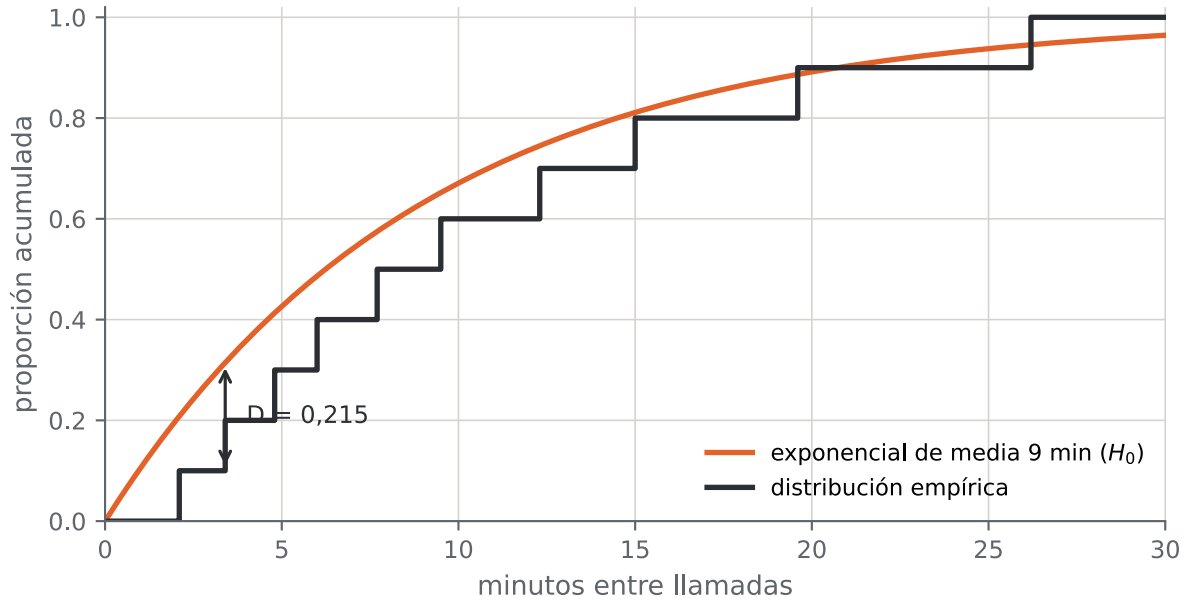
Pregunta. ¿Los tiempos siguen la exponencial de media 9 que dice la central?

Hipótesis. H_0: $F_0(x) = 1 - e^{-x/9}$. H_1: los tiempos no siguen esa distribución. La media viene del historial, **no de estos datos**: F_0 está completamente especificada y la tabla de KS vale.

Estadístico.

i	$x_{(i)}$	i/n	$F_0(x_{(i)})$	D_i^+	D_i^-
1	2,1	0,1	0,2081	-0,1081	0,2081
2	3,4	0,2	0,3146	-0,1146	0,2146
3	4,8	0,3	0,4134	-0,1134	0,2134
4	6,0	0,4	0,4866	-0,0866	0,1866
5	7,7	0,5	0,5750	-0,0750	0,1750
6	9,5	0,6	0,6520	-0,0520	0,1520
7	12,3	0,7	0,7450	-0,0450	0,1450
8	15,0	0,8	0,8111	-0,0111	0,1111
9	19,6	0,9	0,8867	0,0133	0,0867
10	26,2	1,0	0,9456	0,0544	0,0456

($D_i^- = F_0(x_{(i)}) - (i-1)/n$.) El máximo está en $D_2^- = \mathbf{0{,}2146}$: a los 3,4 minutos la exponencial predice que el 31 % de los tiempos ya terminó, y en la muestra solo había terminado el 10 % (uno de diez). Fíjate que con solo D^+ el máximo habría sido 0,0544.



Valor p y región de rechazo. Para $n = 10$ y $\alpha = 0{,}05$, $D_{10;\,0{,}05} = 0{,}409$. Como $0{,}2146 < 0{,}409$, no se rechaza: p = 0,672.

Conclusión. Los 10 tiempos son compatibles con la exponencial de media 9 minutos de la central. Con 10 datos esto es poco exigente: la prueba no detectaría diferencias moderadas.

Parte C · Con Python, y una advertencia sobre la normal

```
from scipy import stats
import numpy as np

conteo = [27, 36, 30, 17, 10]                  # 0, 1, 2, 3 y «4 o más»
lam = 1.6
p = [stats.poisson.pmf(k, lam) for k in range(4)] + [stats.poisson.sf(3, lam)]
stats.chisquare(conteo, 120 * np.array(p), ddof=1)   # ddof=1: un parámetro estimado → gl =
3

t = [2.1, 3.4, 4.8, 6.0, 7.7, 9.5, 12.3, 15.0, 19.6, 26.2]
stats.kstest(t, "expon", args=(0, 9))          # loc = 0, scale = media → D = 0,2146
stats.shapiro(t)                               # W = 0,920
```

`chisquare` y `kstest` devuelven exactamente lo calculado a mano. El cuaderno `notebooks/u05_bondad_de_ajuste.ipynb` lo reproduce con `datos/u05_pizzeria_llamadas.csv` y `datos/u05_pizzeria_tiempos.csv`.

Shapiro-Wilk sobre los mismos 10 tiempos da W = 0,920 y p = 0,357: **tampoco rechaza la normalidad**. Los datos no pueden ser normales y exponenciales a la vez; lo que pasa es que con 10 datos ninguna de las dos pruebas tiene fuerza para descartar nada. Un tiempo de espera no puede ser negativo y su distribución es asimétrica: la exponencial tiene sentido físico; la normal, no. El modelo se elige por el mecanismo y se contrasta con la prueba, no al revés.

Cómo se lee. El conteo por intervalo y los tiempos entre llamadas cuentan la misma historia: llamadas al azar a razón de 1,6 cada 15 minutos (una cada 9 a 9,4 minutos). La pizzería puede usar un modelo de colas con llegadas de Poisson para decidir cuántas personas contestan. Antes de fijarlo, conviene juntar más tiempos: con 10 datos, el KS solo descarta modelos muy equivocados.

10. Errores típicos

Error	Cómo evitarlo
Concluir «los datos son normales» (o «son Poisson») porque no se rechazó	La conclusión es «el modelo es compatible con los datos»; con pocos datos casi nada se rechaza
No descontar los parámetros estimados en la chi-cuadrado	$gl = k - 1 - m$, con k contado **después** de agrupar
Agrupar mirando las observadas	Se agrupa hasta que cada **esperada** sea al menos 5
Usar la tabla de KS con la media y la desviación sacadas de los mismos datos	Es Lilliefors: usa `lilliefors` de statsmodels o Anderson-Darling con sus valores corregidos
Calcular D solo con $i/n - F_0(x_{(i)})$	Se calculan D^+ y D^-; el máximo puede estar en la parte baja del escalón
Usar KS para conteos	KS supone F_0 continua; para conteos, chi-cuadrado
Mirar el valor p de Shapiro y no el Q-Q	El Q-Q dice cómo falla el ajuste (asimetría, colas, un atípico) y qué hacer
Rechazar normalidad con 5.000 datos y abandonar la prueba t	Con n grande se detectan desvíos sin importancia; el Q-Q y el tamaño muestral deciden
Probar normalidad de la variable cruda en un ANOVA	El supuesto es sobre los **residuos** (unidades 7 y 9)

11. Práctica

Diez ejercicios: 5.1 a 5.4 básicos, 5.5 a 5.8 intermedios, 5.9 y 5.10 de desafío. Usa $\alpha = 0{,}05$ salvo que se diga otra cosa. Las pautas están en la sección 12.

5.1 · Grados de libertad (básico). Para cada caso, di los grados de libertad y el valor crítico $\chi^2_{0{,}95}$. (a) Un dado: 6 caras, H_0: equilibrado. (b) Llegadas por minuto con Poisson y λ estimado; 8 clases de las cuales las tres últimas se agrupan en una. (c) Una normal con μ y σ estimadas, 8 clases. (d) Una binomial con $n = 4$ y $p = 0{,}3$ que fija el fabricante, 5 clases (0 a 4).

5.2 · Boletas por día (básico). Una ferretería de Los Ángeles quiere saber si el sábado necesita más cajeros. En una semana típica emitió estas boletas. ¿Los días son igual de cargados?

Día	lunes	martes	miércoles	jueves	viernes	sábado
Boletas	58	44	41	47	52	68

5.3 · Bolsas de harina (básico). Un molino declara que el peso de sus bolsas de 1 kg es normal con media 1.000 g y desviación 8 g. Una panadería pesa 6 bolsas: 991, 1.004, 996, 1.013, 1.000 y 1.009 g. Haz la prueba de Kolmogorov-Smirnov a mano contra la distribución declarada.

5.4 · Un Q-Q a mano (básico). Seis pernos miden 49,2; 49,8; 50,0; 50,1; 50,4 y 51,9 mm. (a) Calcula las posiciones de Blom y los cuantiles normales z_i. (b) Calcula la correlación entre los datos ordenados y los z_i y repítela sin el perno de 51,9 mm. (c) Shapiro-Wilk da W = 0,886. ¿Qué dicen el Q-Q y la prueba?

5.5 · Fallas en rollos de tela (intermedio). Una tejeduría revisa 100 rollos y cuenta las fallas de cada uno. ¿Las fallas por rollo siguen una Poisson? Si no, ¿qué patrón muestran los datos?

Fallas por rollo	0	1	2	3	4	5
Rollos	40	26	15	10	5	4

5.6 · Frascos defectuosos por caja (intermedio). Una envasadora revisa 150 cajas de 4 frascos y cuenta los defectuosos de cada caja. ¿Sigue una binomial con $n = 4$ y p estimado? Si los frascos salieran malos «por tandas» (una caja con uno malo tiende a tener más), ¿qué clase mostraría el problema?

Defectuosos por caja	0	1	2	3	4
Cajas	96	42	10	2	0

5.7 · Paquetes de café (intermedio). Una tostaduría pesó 200 paquetes; la media fue 250,1 g y la desviación 2,9 g. Contrasta normalidad con chi-cuadrado usando estas clases.

Peso (g)	menos de 246	246 a 248	248 a 250	250 a 252	252 a 254	254 o más
Paquetes	18	27	52	49	37	17

5.8 · El mismo D, dos conclusiones (intermedio). Un analista contrasta la normalidad de 50 tiempos de proceso. Estima μ y σ con la muestra y obtiene $D = 0{,}152$. (a) ¿Qué concluye con la tabla de KS? (b) ¿Y con el valor crítico de Lilliefors? (c) ¿Cuál vale y por qué?

5.9 · Anderson-Darling a mano (desafío). Un servicio técnico afirma que sus tiempos de reparación son exponenciales con media 4 horas. Cinco reparaciones duraron 0,6; 1,9; 3,1; 5,2 y 11,8 h. (a) Calcula A^2 y D y decide con cada uno. (b) Cambia el último tiempo por 24,0 h y recalcula los dos. ¿Cuál reacciona más a una cola larga y por qué?

5.10 · Medir el error de usar KS con parámetros estimados (desafío). Con Python y la semilla 505, simula 5.000 muestras de 30 datos de una normal estándar. En cada una estima media y desviación y calcula D contra esa normal ajustada. (a) ¿Qué fracción supera el valor crítico de la tabla de KS para $n = 30$? (b) ¿Cuál es el percentil 95 de los D simulados y cómo se compara con el de Lilliefors? (c) ¿Qué fracción supera el valor de Lilliefors?

```
rng = np.random.default_rng(505)
D = []
for _ in range(5000):
    m = rng.normal(0, 1, 30)
    D.append(stats.kstest(m, stats.norm(m.mean(), m.std(ddof=1)).cdf).statistic)
```

12. Pautas

5.1. (a) Nada se estima: 5 gl, $\chi^2_{0,95}$ = 11,07. (b) Quedan 6 clases y se estimó λ: 4 gl, 9,49. (c) Se estimaron dos parámetros: $8 - 1 - 2$ = 5 gl, 11,07. (d) p viene del fabricante: 4 gl, 9,49. Los mismos grados de libertad pueden salir de caminos distintos; lo que importa es contar clases finales y parámetros sacados de los datos.

5.2. Hay 310 boletas: bajo H_0 cada día espera $310/6 = 51{,}67$. Los aportes son 0,776, 1,138, 2,202, 0,422, 0,002 y 5,163 (el sábado aporta más de la mitad). $\chi^2 = 9{,}70$ con 5 gl; el valor crítico es 11,07 y p = 0,084. No se rechaza al 5 %: con una semana de datos no hay evidencia suficiente de que los días difieran. **No** significa que sean iguales: el sábado está 32 % sobre el promedio. Antes de decidir los cajeros conviene juntar cuatro o cinco semanas; si el patrón se mantiene, la prueba lo va a detectar.

5.3. Ordenados: 991, 996, 1.000, 1.004, 1.009, 1.013. Con $F_0 = \Phi\left((x - 1.000)/8\right)$: 0,1303; 0,3085; 0,5000; 0,6915; 0,8697; 0,9479. Los D^- son 0,1303; 0,1419; 0,1667; 0,1915; 0,2030 y 0,1146, y los D^+ no pasan de 0,0521. $D = 0{,}2030$, menor que $D_{6;\,0{,}05} = 0{,}519$: no se rechaza (p = 0,925). Las bolsas son compatibles con lo que declara el molino. Con 6 bolsas el valor crítico es enorme: la prueba solo detectaría un incumplimiento grosero.

5.4. (a) Posiciones $(i - 0{,}375)/6{,}25$: 0,100; 0,260; 0,420; 0,580; 0,740; 0,900. Cuantiles: -1,28; -0,64; -0,20; 0,20; 0,64; 1,28. (b) La correlación del Q-Q es 0,929; sin el perno de 51,9 sube a 0,966. (c) Shapiro da W = 0,886 y p = 0,296: no rechaza. El Q-Q, en cambio, muestra cinco puntos casi en recta y uno muy arriba: un perno 1,5 mm más largo que el siguiente. Con 6 datos la prueba no tiene potencia para declararlo raro, pero el gráfico ya lo señala. Hay que revisar ese perno (¿otro lote, un error de medición?) antes de suponer normalidad.

5.5. $\hat{\lambda} = 126/100 = 1{,}26$. Esperadas para 0 a 5 o más: 28,37; 35,74; 22,52; 9,46; 2,98 y 0,94. Se agrupa en «3 o más» (o = 19, e = 13,38).

Clase	0	1	2	3 o más
o_i	40	26	15	19
e_i	28,37	35,74	22,52	13,38
Aporte	4,77	2,65	2,51	2,36

$\chi^2 = 12{,}30$ con $4 - 1 - 1 = 2$ gl (crítico 5,99): se rechaza, p = 0,0021. El patrón: sobran rollos sin fallas **y** rollos con muchas, y faltan los del medio. La varianza de los conteos (1,99) es casi el doble de la media (1,26), y en una Poisson son iguales. Eso es **sobredispersión**: típico de dos poblaciones mezcladas (un telar bueno y uno con problemas). La acción es separar los rollos por telar y repetir la prueba en cada uno.

5.6. $\hat{p} = 68/600 = 0{,}1133$. Esperadas con la binomial(4; 0,1133) para 0 a 4: 92,71; 47,40; 9,09; 0,77 y 0,02. Las tres últimas se agrupan en «2 o más» (o = 12, e = 9,89). Con 3 clases y un parámetro queda 1 gl. $\chi^2 = 1{,}184$, menor que 3,84: no se rechaza (p = 0,277). Los defectuosos por caja son compatibles con frascos que fallan de forma independiente. Si fallaran por tandas, el exceso aparecería en la clase «2 o más» (y en la de 0), como en 5.5.

5.7. Con Φ y media 250,1 y desviación 2,9, las probabilidades de las clases son 0,0787; 0,1558; 0,2518; 0,2576; 0,1668 y 0,0893, y las esperadas, 15,74; 31,16; 50,35; 51,52; 33,37 y 17,87 (todas sobre 5). $\chi^2 = 1{,}49$ con $6 - 1 - 2 = 3$ gl (crítico 7,81): no se rechaza, p = 0,684. El peso de los paquetes es compatible con una normal; la tostaduría puede usarla para estimar cuántos paquetes quedan bajo el peso declarado.

5.8. (a) Tabla de KS: $1{,}36/\sqrt{50} = 0{,}192$. Como $0{,}152 < 0{,}192$, no rechaza (p = 0,179). (b) Lilliefors: $0{,}886/\sqrt{50} = 0{,}125$. Como $0{,}152 > 0{,}125$, rechaza (p = 0,006). (c) Vale Lilliefors: la media y la desviación salieron de los mismos 50 datos, así que la normal ajustada ya está «acomodada» a la muestra y D es naturalmente más chico. La tabla de KS supone una F_0 fija y aquí da una conclusión equivocada.

5.9. (a) Con $F_0 = 1 - e^{-x/4}$: F_i = 0,1393; 0,3781; 0,5393; 0,7275; 0,9477. Los términos $(2i-1)\,[\ln F_i + \ln(1 - F_{6-i})]$ son -4,921; -6,818; -6,962; -5,552 y -1,834; suman -26,087, así que $A^2 = -5 + 26{,}087/5 = 0{,}217$. Es menor que 2,492: no se rechaza. KS: D = 0,1781, menor que $D_{5;\,0{,}05} = 0{,}563$ (p = 0,989). (b) Con 24,0 h, F_5 pasa a 0,9975: A^2 sube a 0,735 (más del triple) y D solo a 0,1975. Ninguno rechaza todavía con 5 datos, pero Anderson-Darling **reacciona mucho más**: su peso $1/[F_0(1-F_0)]$ es enorme cuando F_0 está cerca de 1, justo donde cae una reparación muy larga. Si lo que preocupa son las reparaciones eternas, Anderson-Darling es la prueba.

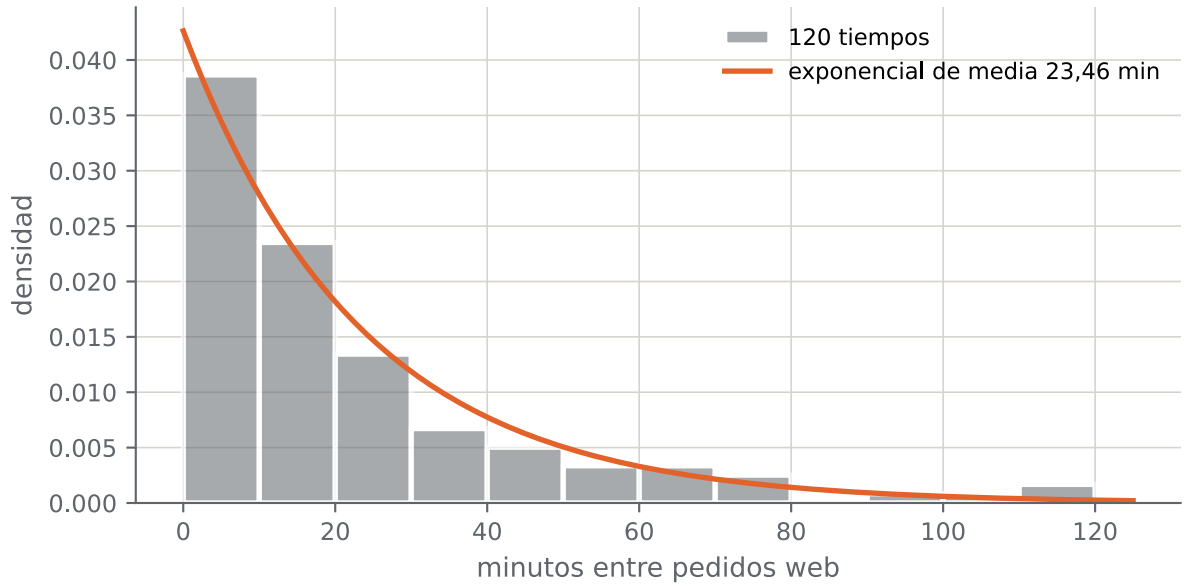
5.10. (a) De las 5.000 muestras, 0 de 5.000 superan el valor de la tabla de KS para $n = 30$ (0,242): 0,00 %, cuando debería ser 5 %. La prueba nunca habría rechazado una normal verdadera, y por lo mismo casi nunca rechazaría una falsa. (b) El percentil 95 simulado es 0,157, al lado del de Lilliefors ($0{,}886/\sqrt{30} = 0{,}162$) y lejos de 0,242. (c) Con el valor de Lilliefors se rechaza el 4,2 % de las veces: muy cerca del 5 % nominal (la diferencia es el error de la aproximación y de la simulación). La simulación es la prueba de la sección 4: estimar los parámetros achica D, y la tabla tiene que corregirse.

---

13. Caso integrador · Estampa Sur, ¿cómo llegan los pedidos web?

> Estampa Sur es el taller ficticio que recorre el ramo. Sus datos son simulados con semilla fija por `verificacion/caso_estampa_sur_datos.py` (en `datos/`). **Lo que trae de la unidad 4:** el tipo de reclamo depende del canal de venta (χ^2 = 21,07; p < 0,001), y el canal web reúne 150 de los 335 reclamos. Para planificar ese canal (cuántas personas lo atienden, cada cuánto se revisa) el taller necesita un modelo de cómo llegan sus pedidos.

Los datos. `datos/llegadas.csv`: 120 tiempos entre pedidos web consecutivos, en minutos. Media 23,46 min, desviación 25,94 min, mediana 13,2 min, de 0,3 a 122,2 min. Que la desviación sea casi igual a la media (coeficiente de variación 1,11) y la mediana mucho menor que la media ya apunta a una exponencial: en ella, la desviación es igual a la media y la mediana es el 69 % de la media.



La pregunta. ¿Los tiempos entre pedidos siguen una exponencial? (Si es así, los pedidos llegan como un proceso de Poisson.)

Supuestos. Pedidos independientes; una sola tasa en el período (si de noche llegaran muchos menos, habría que separar franjas).

Prueba 1 · Kolmogorov-Smirnov. H_0: exponencial; la media se estima con los datos (23,46). El script del caso obtiene D = 0,0746 y p = 0,49. Pero la media salió de los mismos datos: ese valor p es optimista (sección 4). Lilliefors para la exponencial, con el mismo D, da p = 0,32. Las dos versiones no rechazan; la corregida es la que vale.

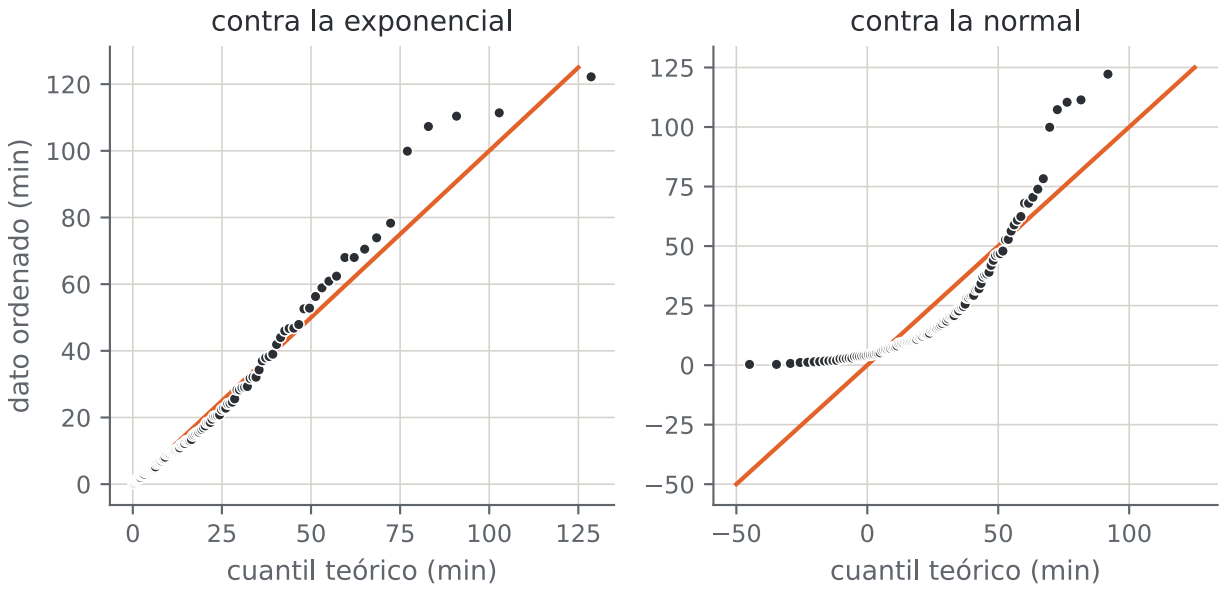
Prueba 2 · Chi-cuadrado por clases. Con la exponencial de media 23,46, $p_i = e^{-a/23{,}46} - e^{-b/23{,}46}$ para cada clase $[a, b)$:

Minutos	0 a 10	10 a 20	20 a 30	30 a 45	45 a 60	60 o más
Observados	46	28	16	10	8	12
Esperados	41,64	27,19	17,76	15,78	8,33	9,30
Aporte	0,456	0,024	0,174	2,118	0,013	0,783

$\chi^2 = 3{,}57$ con $6 - 1 - 1 = 4$ gl (crítico 9,49): no se rechaza, p = 0,47. El mayor aporte está entre 30 y 45 minutos (hubo 10 tiempos donde se esperaban 16), pero es una diferencia que el azar explica.

Prueba 3 · Anderson-Darling. Contra la exponencial con la media estimada, A^2 = 0,722; el valor crítico al 5 % para este caso (escala estimada) es 1,314. No se rechaza (p ≥ 0,15). Como mira las colas, confirma que los tiempos largos (sobre 60 minutos) también calzan.

Prueba 4 · ¿Y si se hubiera supuesto normalidad? Shapiro-Wilk da W = 0,774, p < 0,001: se rechaza con fuerza. El Q-Q lo muestra: contra la exponencial los puntos siguen la recta (los cuatro tiempos más largos quedan algo por encima, una cola un poco más pesada que Anderson-Darling no alcanza a rechazar); contra la normal se curvan hacia arriba (asimetría a la derecha) y los primeros quedan por encima de la recta porque un tiempo no puede ser negativo.



```
x = pd.read_csv("datos/llegadas.csv").minutos
stats.kstest(x, "expon", args=(0, x.mean()))      # D = 0,0746; p optimista
lilliefors(x, dist="exp")                         # mismo D; p corregido
stats.anderson(x, dist="expon", method="interpolate")
stats.shapiro(x)
```

Lectura. Las tres pruebas de ajuste coinciden: los tiempos entre pedidos web son compatibles con una exponencial de media 23,46 minutos, es decir, una llegada de Poisson con $\lambda = 60/23{,}46 = 2{,}56$ pedidos por hora. Con ese modelo el taller puede calcular, por ejemplo, la probabilidad de que pase más de una hora sin pedidos: $e^{-60/23{,}46}$ = 7,8 %. No hay que leerlo como «los tiempos son exponenciales»: es el modelo más simple que los datos no contradicen, y basta para dimensionar la atención del canal web.

Lo que pasa a las unidades siguientes. Dos cosas. Primero, la herramienta: Shapiro-Wilk y el Q-Q vuelven en las unidades 7, 9 y 10, aplicados a los **residuos** del ANOVA y de la regresión. Segundo, la advertencia: los tiempos de espera, los montos y los conteos rara vez son normales; antes de aplicarles una prueba t hay que mirar su forma (o usar el modelo que les corresponde, como la Poisson de la unidad 11). La unidad 6 cambia de pregunta: ya no la forma de una variable, sino cuánto se mueven juntas dos (el precio y las unidades vendidas).

---

14. Para seguir

En los libros del ramo.

- Walpole, Myers, Myers y Ye, *Probability & Statistics for Engineers & Scientists* (Pearson, 2017), la sección de prueba de bondad de ajuste del capítulo de pruebas de una y dos muestras: la chi-cuadrado con parámetros estimados.
- Casella y Berger, *Statistical Inference* (Cengage, 2021): la distribución empírica y por qué la de D no depende de F_0 (la transformación $F_0(X)$ uniforme).

Abiertos y gratis.

- NIST/SEMATECH, *e-Handbook of Statistical Methods*, en inglés: sección 1.3.5.16 «Kolmogorov-Smirnov Goodness-of-Fit Test» (https://www.itl.nist.gov/div898/handbook/eda/section3/eda35g.htm) y sección 1.3.5.14 «Anderson-Darling Test» (https://www.itl.nist.gov/div898/handbook/eda/section3/eda35e.htm).
- Diez, Çetinkaya-Rundel y Barr, *OpenIntro Statistics* (4.ª ed.), sección 6.3 «Testing for goodness of fit using chi-square», en inglés: https://www.openintro.org/book/os/

Con el tutor. Pega `tutor/contexto.md` al inicio de la conversación con cualquier IA y pídele, por ejemplo: «Dame una tabla de conteos que parezca Poisson pero tenga sobredispersión, y corrígeme la chi-cuadrado paso a paso, incluidos los grados de libertad».
