Unidad 8 · Comparaciones múltiples

Qué vas a poder hacer. Después de un ANOVA que rechaza, decir **qué pares de grupos difieren** sin inflar el riesgo de falsas alarmas: calcular la tasa de error por familia, ajustar con Bonferroni, aplicar Tukey (HSD) a mano y con Python, comparar contra un control con Dunnett, reconocer cuándo usar Scheffé, y leer la tabla de Tukey y sus intervalos simultáneos para tomar una decisión.

Lo que necesitas antes. De la unidad 2, la prueba t y el intervalo para una diferencia de medias. De la unidad 7, la tabla ANOVA de un factor: sobre todo el CME y sus grados de libertad, que acá se reutilizan en cada comparación.

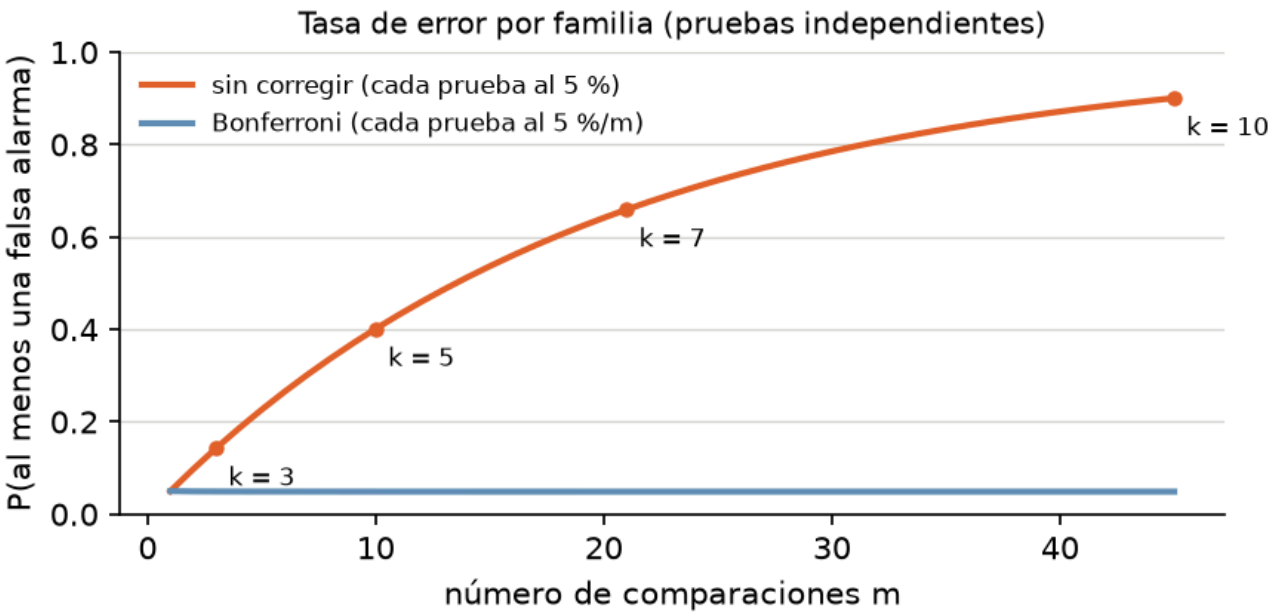
Tiempo. Unas 5 horas: 2 de lectura con el ejemplo y 3 de práctica.

---

1. El problema · muchas preguntas, un solo riesgo

El ANOVA de la unidad 7 dice si **alguna** media difiere. La pregunta práctica casi siempre es otra: **cuáles**. Con k grupos hay $m = k(k-1)/2$ pares. Si cada par se prueba al 5 %, cada prueba tiene un 5 % de falsa alarma, pero la **familia** de pruebas tiene mucho más:

$$\text{tasa de error por familia} = P(\text{al menos una falsa alarma}) = 1 - (1-\alpha)^m \quad \text{(pruebas independientes)}$$



Las comparaciones de pares no son independientes (comparten grupos y el mismo CME), así que la cifra exacta es algo menor, pero la conclusión no cambia: **sin corrección, buscar diferencias entre muchos grupos garantiza encontrar alguna**. El ejercicio 8.9 lo mide con una simulación.

Hay dos maneras de pensar el error:

- **Tasa por comparación:** cada prueba al 5 %. Es lo que hace una prueba t suelta.

- **Tasa por familia:** la probabilidad de que **alguna** de las m conclusiones sea una falsa alarma quede en 5 %. Es lo que exige quien va a actuar sobre la lista completa de diferencias.

Todos los métodos de esta unidad controlan la tasa por familia. Difieren en **qué familia** cubren (todos los pares, solo contra un control, cualquier contraste) y por eso en cuánto se ensanchan los intervalos.

Lo común a todos. Comparan medias con el error estándar que sale del ANOVA:

$$ee(\bar{y}_i - \bar{y}_j) = \sqrt{CME\left(\frac{1}{n_i} + \frac{1}{n_j}\right)} \qquad \text{con } N - k \text{ gl}$$

Usar el CME (que junta la información de todos los grupos) en vez de la varianza de solo los dos grupos comparados da más grados de libertad y más precisión. Por eso los supuestos del ANOVA (normalidad de residuos, varianzas iguales, independencia) siguen valiendo acá.

---

2. Bonferroni · repartir el 5 %

La idea más simple: si se hacen m pruebas y se quiere que la familia tenga a lo más α, cada prueba se hace al nivel α/m. Funciona por la desigualdad de Boole: la probabilidad de que ocurra alguno de m eventos es a lo más la suma de sus probabilidades, $m \cdot \alpha/m = \alpha$.

En la práctica hay tres formas equivalentes de aplicarlo:

Forma	Cómo
Valor crítico	rechazar si $\lvert t_{ij}\rvert > t_{1-\alpha/(2m),\,N-k}$
Diferencia mínima	rechazar si $\lvert\bar{y}_i - \bar{y}_j\rvert > t_{1-\alpha/(2m),\,N-k} \cdot ee$
Valor p ajustado	$p_{Bonf} = \min(1,\ m \cdot p)$ y comparar con α

Cuándo conviene. Cuando las comparaciones son **pocas y elegidas antes de ver los datos** (por ejemplo, tres preguntas concretas). Sirve para cualquier tipo de prueba, no solo medias. Su defecto: con muchas comparaciones es **conservador** (la familia queda bajo el 5 % y se pierden diferencias reales).

Holm, la versión escalonada. Ordena los m valores p de menor a mayor y compara el más chico con α/m, el segundo con $\alpha/(m-1)$, y así hasta el primero que no rechaza; ahí se detiene. Controla la misma tasa por familia y nunca rechaza menos que Bonferroni. `multipletests(p, method="holm")` lo hace.

---

3. Tukey (HSD) · todos los pares, con exactitud

Si la pregunta es **todos los pares**, la pregunta de fondo es: ¿la diferencia más grande entre medias es más grande de lo que el azar produce? Con n datos por grupo y bajo H_0, la distribución de

$$q = \frac{\bar{y}_{max} - \bar{y}_{min}}{\sqrt{CME/n}}$$

es conocida: la **distribución del rango studentizado** $q_{k,\,N-k}$, que depende del número de grupos y de los gl del error. Si la diferencia más grande no supera el percentil 95 de q, ninguna otra lo hace. Por eso Tukey controla la tasa por familia **exactamente** en 5 % para todos los pares en un diseño balanceado.

La diferencia honestamente significativa:

$$HSD = q_{1-\alpha;\,k,\,N-k}\sqrt{\frac{CME}{n}} \qquad \text{el par } (i,j) \text{ difiere si } |\bar{y}_i - \bar{y}_j| > HSD$$

Intervalos simultáneos: $(\bar{y}_i - \bar{y}_j) \pm HSD$. Todos juntos cubren las diferencias reales con 95 % de confianza. Si el intervalo de un par **no contiene el 0**, ese par difiere.

Datos desbalanceados (Tukey-Kramer). Se reemplaza $\sqrt{CME/n}$ por $\sqrt{\frac{CME}{2}\left(\frac{1}{n_i}+\frac{1}{n_j}\right)}$: cada par tiene su propio HSD. Es lo que hace `pairwise_tukeyhsd`. (Algunos apuntes dicen que Tukey exige grupos del mismo tamaño: con la corrección de Kramer no hace falta, y la tasa por familia queda en 5 % o un poco menos.)

La tabla de q. Se entra con k (número de grupos, no de pares) y con los gl del error. Con Python: `stats.studentized_range.ppf(0.95, k, gl)`.

> **Relación con la t.** $q = \sqrt{2}\cdot|t|$ para un par. Tukey es una prueba t cuyo valor crítico sale de pensar en el par más distante de todos, no en uno solo.

---

4. Scheffé · cualquier contraste (mención)

Un **contraste** es una combinación $L = \sum_i c_i\mu_i$ con $\sum_i c_i = 0$: un par ($c = 1, -1$), o «el promedio de dos métodos nuevos contra el promedio de dos viejos» ($c = \frac{1}{2}, \frac{1}{2}, -\frac{1}{2}, -\frac{1}{2}$). Su estimación y error estándar son

$$\hat{L} = \sum_i c_i\bar{y}_i \qquad ee(\hat{L}) = \sqrt{CME\sum_i \frac{c_i^2}{n_i}}$$

Scheffé protege **todos los contrastes posibles a la vez**, incluso los que se inventan después de mirar los datos. Rechaza si $|\hat{L}/ee| > \sqrt{(k-1)\,F_{1-\alpha;\,k-1,\,N-k}}$.

Dos propiedades lo hacen útil: (1) es **coherente con el F**: si el ANOVA rechaza, existe al menos un contraste que Scheffé declara significativo (aunque puede no ser un par); (2) por cubrir tanto, es el más **conservador** para pares: para comparar pares, Tukey es mejor.

---

5. Dunnett · todos contra un control

Muchas veces hay un **control** (el proceso actual, el placebo, el proveedor de siempre) y la única pregunta es si cada alternativa difiere de él. Son $k-1$ comparaciones, no $k(k-1)/2$. Dunnett usa la distribución conjunta de esas $k-1$ estadísticas t (que están correlacionadas porque todas usan el mismo control) y obtiene un valor crítico menor que el de Tukey y que el de Bonferroni con $k-1$ pruebas:

$$|\bar{y}_i - \bar{y}_{control}| > d_{1-\alpha;\,k-1,\,N-k}\cdot\sqrt{CME\left(\frac{1}{n_i}+\frac{1}{n_c}\right)}$$

Con Python: `stats.dunnett(*tratamientos, control=control)` entrega los valores p ajustados y, con `.confidence_interval()`, los intervalos simultáneos. El cálculo es numérico: se fija la semilla (`rng=`) para que dé siempre lo mismo.

6. Cuál usar

Pregunta	Método	Por qué
¿Qué pares difieren, todos contra todos?	**Tukey**	exacto para todos los pares; intervalos más angostos que Bonferroni
¿Alguna alternativa difiere del proceso actual?	**Dunnett**	solo $k-1$ comparaciones; más potencia que Tukey para esa pregunta
Pocas comparaciones fijadas **antes** de ver los datos	**Bonferroni** (o Holm)	simple y sirve para cualquier prueba
Contrastes que se te ocurren **después** de mirar los datos	**Scheffé**	el único que protege lo que se elige mirando
Pruebas t sueltas sin corregir (LSD de Fisher)	no se recomienda	solo protege si el ANOVA rechazó y hay 3 grupos; con más, la familia pierde el 5 %

El método se elige antes de mirar los resultados. Probar los cuatro y quedarse con el que da más diferencias es otra forma de hacer muchas pruebas.

7. Cómo leer la salida de Tukey

`pairwise_tukeyhsd` de `statsmodels` entrega una fila por par:

Columna	Qué es
`group1`, `group2`	el par; los grupos van en orden alfabético
`meandiff`	la media de `group2` **menos** la de `group1` (ojo con el signo)
`p-adj`	el valor p **ya ajustado** por Tukey: se compara directo con 0,05
`lower`, `upper`	el intervalo simultáneo al 95 % para `meandiff`
`reject`	`True` si el par difiere (equivale a `p-adj < 0,05` y a que el intervalo no contenga el 0)

Letras de agrupamiento. Una forma compacta de informar: se ordenan las medias y se da la misma letra a los grupos que **no** difieren. Dos grupos sin letra en común difieren; un grupo con «ab» no se distingue ni de los «a» ni de los «b». Las letras no son transitivas: que A se parezca a B y B a C no dice que A se parezca a C.

8. Con Python

```
from scipy import stats
from statsmodels.stats.multicomp import pairwise_tukeyhsd
from statsmodels.stats.multitest import multipletests

tk = pairwise_tukeyhsd(df.kg_hora, df.capacho, alpha=0.05)    # Tukey(-Kramer)
print(tk)
tk.plot_simultaneous()                                        # intervalos simultáneos
p_bonf = multipletests(p_sin_corregir, method="bonferroni")[1]
p_holm = multipletests(p_sin_corregir, method="holm")[1]
d = stats.dunnett(liviano, arnes, doble, control=actual, rng=np.random.default_rng(1))
print(d.pvalue, d.confidence_interval(0.95))
q = stats.studentized_range.ppf(0.95, k, gl_error)           # el valor de la tabla de Tukey
```

El cuaderno `notebooks/u08_comparaciones_multiples.ipynb` reproduce el ejemplo y el caso, con las pruebas t de pares hechas con el CME.

---

9. Ejemplo resuelto · capachos para cosechar arándanos

Un huerto de arándanos de Ñuble prueba tres capachos nuevos (el balde que el cosechero lleva al cuerpo) contra el **actual**: uno liviano, uno con arnés y uno doble. Asignó al azar 20 cosecheros con experiencia parecida, 5 por capacho, y midió los kg cosechados por hora en una jornada.

Capacho	1	2	3	4	5	Media
actual	9,83	10,42	9,47	10,11	10,17	10,000
liviano	10,94	11,58	10,71	11,33	11,44	11,200
arnés	10,27	11,03	10,12	10,79	10,64	10,570
doble	10,53	11,12	9,97	10,92	10,90	10,688

Paso 1 · ANOVA (unidad 7). $F = 7{,}96$ con 3 y 16 gl, $p = 0{,}002$; $CME = 0{,}1523$. Algún capacho difiere. Cada par tiene el mismo error estándar, $ee = \sqrt{0{,}1523 \cdot 2/5} = 0{,}2468$.

Paso 2 · Las seis comparaciones con tres criterios. $t = d/ee$ con 16 gl; Bonferroni multiplica el p por 6; Tukey usa $q = \sqrt{2}\,|t|$ contra el rango studentizado con $k = 4$.

Par	d (kg/h)	t	p sin corregir	p Bonferroni	q	p Tukey
liviano − actual	1,20	4,86	< 0,001	0,001	6,88	< 0,001
arnés − actual	0,57	2,31	0,035	0,208	3,27	0,137
doble − actual	0,69	2,79	0,013	0,079	3,94	0,058
arnés − liviano	-0,63	-2,55	0,021	0,128	3,61	0,089
doble − liviano	-0,51	-2,07	0,055	0,327	2,93	0,203
doble − arnés	0,12	0,48	0,639	1,000	0,68	0,963

Sin corregir, **cuatro** pares parecen distintos. Con Bonferroni y con Tukey queda **uno**.

Paso 3 · Tukey a mano. $q_{0{,}95;\,4,\,16} = 4{,}046$ (tabla de Tukey o `studentized_range`).

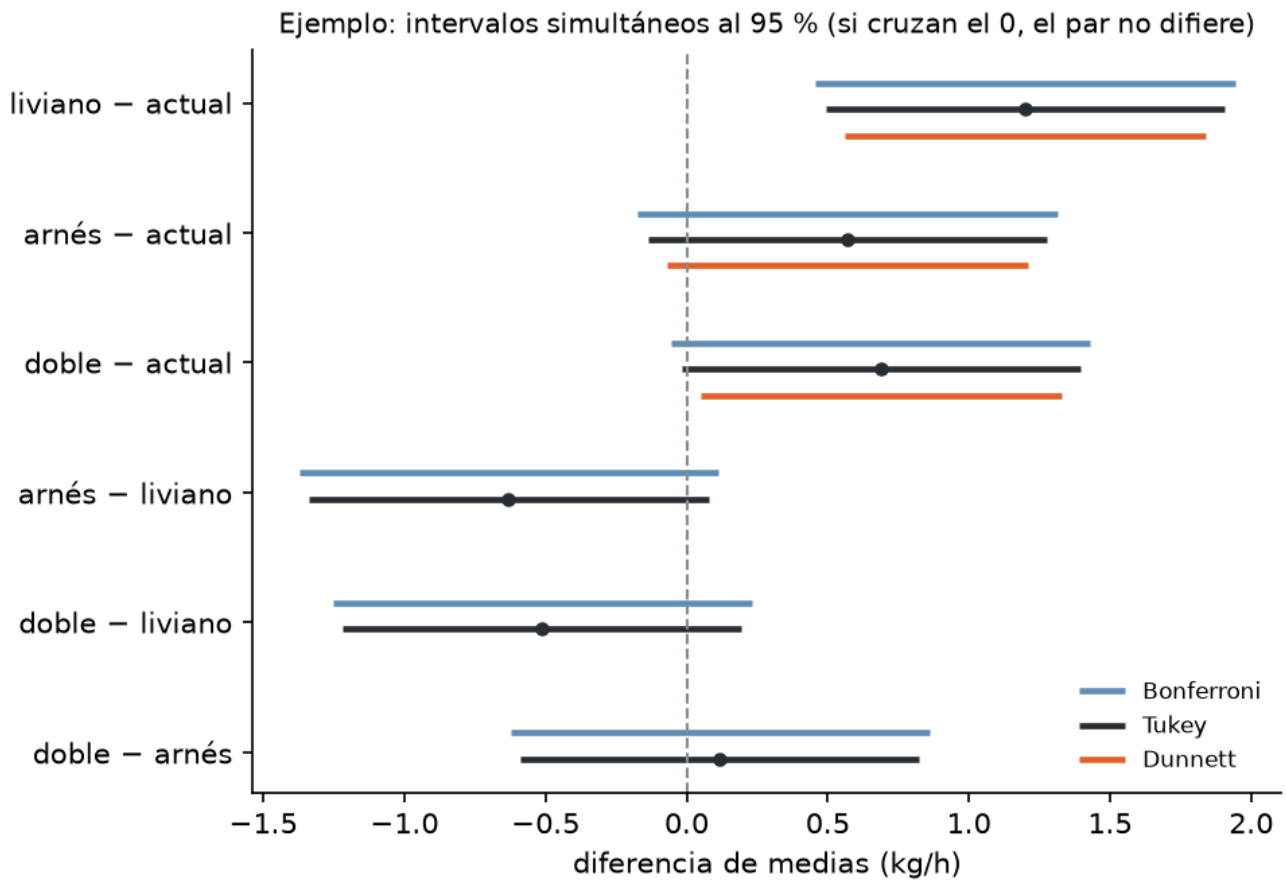
$$HSD = 4{,}046\sqrt{\frac{0{,}1523}{5}} = 0{,}706 \text{ kg/h}$$

Solo liviano − actual (1,20) supera 0,706. Doble − actual (0,69) queda justo debajo. Para comparar, Bonferroni exige $t_{1-0{,}05/12;\,16} = 3{,}008$, es decir una diferencia mínima de $3{,}008 \cdot 0{,}2468 = 0{,}743$: más exigente que Tukey (las pruebas t sueltas usan 2,120).

Par	Tukey: desde	hasta	Bonferroni: desde	hasta
liviano − actual	0,49	1,91	0,46	1,94
arnés − actual	-0,14	1,28	-0,17	1,31
doble − actual	-0,02	1,39	-0,05	1,43
arnés − liviano	-1,34	0,08	-1,37	0,11
doble − liviano	-1,22	0,19	-1,25	0,23
doble − arnés	-0,59	0,82	-0,62	0,86

Paso 4 · La pregunta real era contra el actual: Dunnett. El jefe de cosecha no necesita saber si el arnés le gana al doble; necesita saber cuáles **superan al actual**. Son 3 comparaciones. El valor crítico de Dunnett es 2,592 (contra 2,86 de Tukey en escala t, que es $4{,}046/\sqrt{2}$), así que la diferencia mínima baja a $2{,}592 \cdot 0{,}2468 = 0{,}640$ kg/h.

Capacho	d contra actual	t	p Dunnett	IC 95 % desde	hasta
liviano	1,20	4,86	< 0,001	0,56	1,84
arnés	0,57	2,31	0,086	-0,07	1,21
doble	0,69	2,79	0,034	0,05	1,33



Paso 5 · Letras (Tukey).

Capacho	Media	Grupo
actual	10,00	a
arnés	10,57	ab
doble	10,69	ab
liviano	11,20	b

Cómo se lee. Con la pregunta bien planteada (¿qué capacho supera al actual?, Dunnett, elegido antes de mirar), hay evidencia para dos: el **liviano**, que agrega entre 0,56 y 1,84 kg por hora, y el **doble**, entre 0,05 y 1,33. El liviano es la mejor apuesta: su ganancia es la mayor y la única que sobrevive incluso a Tukey. Entre los tres nuevos no hay evidencia de diferencias (todos comparten letra con alguno). Si se hubieran hecho pruebas t sueltas, el informe habría dicho que el liviano también le gana al arnés y que el arnés le gana al actual: dos afirmaciones que ningún método corregido sostiene.

10. Errores típicos

Error	Cómo evitarlo
Hacer pruebas t de todos los pares y reportar las que dan $p < 0{,}05$	Con m pares la familia supera el 5 %; usar Tukey, Bonferroni o Dunnett según la pregunta
Comparar el `p-adj` de Tukey con $0{,}05/m$	Ya viene ajustado: se compara con 0,05 directo
Leer el signo de `meandiff` al revés	Es `group2` − `group1`, y los grupos van en orden alfabético
Concluir «A y C son iguales» porque comparten letra	No rechazar no prueba igualdad; mirar el intervalo: puede ser ancho
Elegir el método que da más diferencias después de verlos todos	El método se fija antes, según la pregunta
Usar Tukey cuando solo interesa compararse con el control	Dunnett responde esa pregunta con más potencia
Usar la varianza de los dos grupos comparados en vez del CME	El CME y sus $N - k$ gl son los del modelo; si las varianzas difieren mucho, el problema es del ANOVA (unidad 7)
Creer que un F significativo garantiza un par significativo	Puede que lo significativo sea un contraste entre grupos de grupos (ejercicio 8.8)
Informar solo «difiere / no difiere»	Dar la diferencia con su intervalo simultáneo: es lo que sirve para decidir
Creer que Tukey exige grupos de igual tamaño	Tukey-Kramer resuelve el caso desbalanceado

11. Práctica

Diez ejercicios: 8.1 a 8.4 básicos, 8.5 a 8.8 intermedios, 8.9 y 8.10 de desafío. Usa $\alpha = 0{,}05$ por familia. Las pautas están en la sección 12.

8.1 · El tamaño de la familia (básico). Para $k = 3$, 5 y 7 grupos: ¿cuántos pares hay?, ¿a qué nivel se hace cada prueba con Bonferroni?, ¿cuál sería la tasa por familia sin corregir y cuál con Bonferroni, si las pruebas fueran independientes?

8.2 · Tukey desde un resumen (básico). Un vivero compara cuatro mezclas de sustrato para almácigos (gramos de plántula por bandeja), 6 bandejas por mezcla. El ANOVA dio $CME = 2{,}4$ con 20 gl. Las medias son A 15,2; B 17,9; C 16,1; D 19,0. Calcula el HSD, decide qué pares difieren y escribe las letras.

8.3 · Leer una salida (básico). Una tienda en línea mide el tiempo de pago (s) en tres versiones de su página, 8 compras por versión:

Versión	1	2	3	4	5	6	7	8
V1	186	169	203	181	163	197	192	175
V2	157	175	145	168	151	163	179	156
V3	181	197	174	205	188	169	211	193

`pairwise_tukeyhsd` entrega (con coma decimal):

group1	group2	meandiff	p-adj	lower	upper	reject
V1	V2	-21,5000	0,0118	-38,4988	-4,5012	True
V1	V3	6,5000	0,6071	-10,4988	23,4988	False
V2	V3	28,0000	0,0013	11,0012	44,9988	True

Interpreta cada fila en palabras (quién es más rápido y por cuánto), comprueba el ancho de los intervalos con q y el CME, y recomienda una versión.

8.4 · Bonferroni y Holm (básico). Un estudio con 6 comparaciones obtuvo estos valores p sin corregir: 0,003; 0,006; 0,012; 0,030; 0,200 y 0,640. Ajústalos con Bonferroni y con Holm. ¿Cuántas comparaciones son significativas con cada uno?

8.5 · Tukey-Kramer (intermedio). Con los datos del ejercicio 7.5 (horas hasta responder un reclamo: correo 26, 31, 28, 35; formulario web 22, 18, 25, 20, 24, 23; teléfono 15, 19, 14, 17, 20), calcula el HSD de cada par con la corrección de Kramer y decide. Compara con Bonferroni.

8.6 · Dunnett contra el adhesivo actual (intermedio). Una fábrica de tableros prueba tres adhesivos nuevos contra el actual; resistencia de la unión (MPa), 6 probetas cada uno:

Adhesivo	1	2	3	4	5	6
actual	8,42	9,07	8,71	8,93	8,18	8,84
A1	9,03	9,58	9,31	8,82	9,47	9,41
A2	8,62	9,19	8,48	9,04	8,87	8,73
A3	9,38	9,93	9,61	9,24	10,08	9,66

(a) Haz Dunnett contra el actual. (b) Compara sus valores p con Bonferroni para 3 comparaciones y con Tukey. (c) Ordena los cuatro métodos (Dunnett, Bonferroni con 3, Tukey, sin corregir) por la diferencia mínima que exigen y explica el orden.

8.7 · Un contraste con Scheffé (intermedio). Con el resumen de 8.2: las mezclas B y D llevan compost y A y C no. (a) Estima el contraste $L = \frac{1}{2}(\mu_B + \mu_D) - \frac{1}{2}(\mu_A + \mu_C)$ y su error estándar. (b) ¿Es significativo si se planificó antes (prueba t) y si se eligió después de mirar (Scheffé)? (c) Para un par cualquiera, ¿qué diferencia

mínima exigen Scheffé, Tukey y Bonferroni?

8.8 · F significativo y ningún par (intermedio). Minutos para armar un mueble con cuatro versiones del instructivo, 5 personas por versión:

Versión	1	2	3	4	5
V1	41	47	44	38	45
V2	44	41	47	40	45
V3	44	50	47	53	47
V4	48	45	51	47	51

(a) Haz el ANOVA y Tukey. (b) ¿Cómo puede el F rechazar si ningún par difiere? (c) Prueba con Scheffé el contraste $\frac{1}{2}(\mu_3+\mu_4)-\frac{1}{2}(\mu_1+\mu_2)$.

8.9 · Medir la tasa por familia (desafío). Simula 20.000 experimentos con $k=5$ grupos de $n=8$ datos normales con **la misma media** (semilla 708 de `numpy.random.default_rng`). En cada uno haz las 10 pruebas t de pares con el CME, Bonferroni, Tukey y el F del ANOVA. ¿En qué fracción de los experimentos cada método declara al menos una diferencia? ¿Por qué las pruebas sin corregir no llegan al 40,1 % de la fórmula?

8.10 · Planificar el tamaño de muestra (desafío). Un laboratorio va a comparar 4 recetas y quiere que Tukey detecte cualquier diferencia de 1,0 unidades entre dos recetas. Espera una desviación estándar de 1,2. ¿Cuántas réplicas por receta necesita para que el HSD sea a lo más 1,0? (El valor de q cambia con n porque cambian los gl del error.)

---

12. Pautas

8.1.

k	Pares	Nivel por prueba	Sin corregir	Con Bonferroni
3	3	0,0167	14,3 %	4,92 %
5	10	0,0050	40,1 %	4,89 %
7	21	0,0024	65,9 %	4,88 %

Bonferroni deja la familia **bajo** el 5 %: protege, y por eso pierde algo de potencia. Sin corregir, con 7 grupos dos de cada tres estudios «encuentran» algo inexistente.

8.2. $q_{0{,}95;\,4,\,20}=3{,}958$; $\sqrt{2{,}4/6}=0{,}6325$; $HSD=2{,}50$ g. Diferencias: B − A 2,7 (difiere); C − A 0,9; D − A 3,8 (difiere); B − C 1,8; D − B 1,1; D − C 2,9 (difiere).

Mezcla	Media	Grupo
A	15,2	a
C	16,1	ab
B	17,9	bc
D	19,0	c

D es la mejor y se distingue de A y C, pero no de B. Si B es más barata, B es una opción que los datos no permiten descartar.

8.3. Fila 1: V2 tarda 21,5 s menos que V1 (de 4,5 a 38,5 s menos, con 95 % simultáneo); difiere. Fila 2: V3 tarda 6,5 s más que V1, pero el intervalo va de -10,5 a 23,5 y contiene el 0: no hay evidencia de diferencia. Fila 3: V3 tarda 28,0 s más que V2; difiere. Ancho: $CME = 181{,}9286$ con 21 gl, $q_{0{,}95;\,3,\,21} = 3{,}565$, $HSD = 3{,}565\sqrt{181{,}93/8} = 17{,}0$: cada intervalo es la diferencia ± 17,0 s. Recomendación: **V2**, la única más rápida que las otras dos. (Ojo con el signo: `meandiff` es `group2` − `group1`, por eso la primera fila es negativa.)

8.4.

p sin corregir	Bonferroni	Holm
0,003	0,018	0,018
0,006	0,036	0,030
0,012	0,072	0,048
0,030	0,180	0,090
0,200	1,000	0,400
0,640	1,000	0,640

Bonferroni: 2 significativas. Holm: 3 (el tercer p se multiplica por 4, no por 6: $0{,}012 \cdot 4 = 0{,}048$). El cuarto ($0{,}030 \cdot 3 = 0{,}090$) ya no pasa y ahí Holm se detiene. Holm siempre rechaza al menos lo mismo que Bonferroni con la misma protección.

8.5. $CME = 8{,}833$ con 12 gl; $q_{0{,}95;\,3,\,12} = 3{,}773$. Cada par tiene su HSD con $\sqrt{\frac{CME}{2}(1/n_i + 1/n_j)}$:

Par	d (h)	HSD	p Tukey	p Bonferroni
formulario web − correo	-8	5,12	0,0034	0,0039
teléfono − correo	-13	5,32	< 0,001	< 0,001
teléfono − formulario web	-5	4,80	0,0411	0,0501

Los tres pares difieren con Tukey: teléfono es el canal más rápido, después el formulario y al final el correo. Con Bonferroni el último par queda en 0,0501, apenas sobre 0,05: para todos los pares, Tukey es más potente que Bonferroni.

8.6. $CME = 0{,}0916$ con 20 gl; cada comparación con el actual tiene $ee = 0{,}1748$.

Adhesivo	d (MPa)	t	p Dunnett	p Bonferroni (3)	p Tukey
A1	0,578	3,31	0,009	0,011	0,017
A2	0,130	0,74	0,799	1,000	0,878
A3	0,958	5,48	< 0,001	< 0,001	< 0,001

(a) A1 y A3 son más resistentes que el actual; A2 no se distingue. (b) y (c) Diferencia mínima para declarar distinto un adhesivo del actual:

Método	Diferencia mínima (MPa)
Dunnett	0,444
Bonferroni (3)	0,457
Tukey	0,489
sin corregir	0,365

Sin corregir es el más permisivo (y no protege la familia). Entre los que protegen, Dunnett exige menos porque su familia es la más chica (3 comparaciones) y aprovecha que comparten el control; Bonferroni con 3 no aprovecha esa correlación; Tukey cubre 6 pares que acá no interesan.

8.7. (a) $\hat{L} = \frac{1}{2}(17{,}9 + 19{,}0) - \frac{1}{2}(15{,}2 + 16{,}1) = 2{,}80$ g; $ee = \sqrt{2{,}4 \cdot 4 \cdot 0{,}25/6} = 0{,}6325$; $t = 4{,}43$. (b) Planificado: $t_{0{,}975;\,20} = 2{,}086$, significativo. Elegido después: el crítico de Scheffé es $\sqrt{3F_{0{,}95;\,3,\,20}} = 3{,}049$; 4,43 lo supera, también significativo. El compost aumenta el peso de las plántulas en unos 2,8 g por bandeja. (c) Para un par, $ee = 0{,}8944$: Scheffé exige 2,73, Bonferroni (6 pares) 2,62 y Tukey 2,50. Para pares, Scheffé es el más exigente: paga por proteger contrastes que nadie pidió.

8.8. (a) Medias 43,0; 43,4; 48,2; 48,4. $F = 4{,}43$ con 3 y 16 gl, $p = 0{,}019$; $CME = 9{,}825$. Tukey ($HSD = 5{,}67$):

Par	d (min)	p Tukey
V2 − V1	0,4	0,997
V3 − V1	5,2	0,078
V4 − V1	5,4	0,065
V3 − V2	4,8	0,113
V4 − V2	5,0	0,094
V4 − V3	0,2	1,000

Ningún par difiere. (b) El F junta la evidencia de todos los grupos: hay **dos bloques** (V1 y V2 rápidos, V3 y V4 lentos) y ninguna diferencia individual alcanza, pero el patrón completo sí. (c) $\hat{L} = 5{,}1$ min, $ee = 1{,}402$, $t = 3{,}64$ contra el crítico de Scheffé 3,117: significativo, $p = 0{,}019$. Las versiones 3 y 4 del instructivo hacen armar más lento que la 1 y la 2. Scheffé es coherente con el F: cuando el F rechaza, algún contraste lo explica.

8.9. Con la semilla 708, la fracción de experimentos con al menos una «diferencia»:

- pruebas t sin corregir: 27,7 %;
- Bonferroni: 3,9 %;
- Tukey: 5,1 %;
- F del ANOVA: 5,0 %.

```
rng = np.random.default_rng(708)
Y = rng.normal(0, 1, size=(20_000, 5, 8))                # 20.000 experimentos, 5 grupos, 8
datos
medias = Y.mean(axis=2)
cme = ((Y - medias[:, :, None]) ** 2).sum(axis=(1, 2)) / 35
rango = (medias.max(axis=1) - medias.min(axis=1)) / np.sqrt(cme / 8)
print((rango > stats.studentized_range.ppf(0.95, 5, 35)).mean())   # Tukey
```

Tukey y el F quedan en el 5 % nominal (con el error de simulación); Bonferroni queda bajo el 5 % (conservador). Las pruebas sueltas no llegan al 40,1 % de la fórmula porque las 10 comparaciones no son independientes: comparten medias y el mismo CME. Igual son más de cinco veces el 5 % prometido.

8.10. $HSD = q_{0{,}95;\,4,\,4(n-1)} \cdot 1{,}2/\sqrt{n}$. Las últimas filas de la búsqueda:

n	gl del error	q	HSD
18	68	3,725	1,053
19	72	3,719	1,024
20	76	3,715	0,997

Hacen falta **20 réplicas por receta** (80 en total). Casi todo el efecto viene de $\sqrt{n}$: q apenas baja de 3,725 a 3,715. Si 80 ensayos son caros, hay que aceptar detectar solo diferencias mayores o bajar la variabilidad del ensayo.

---

13. Caso integrador · Estampa Sur, qué tintas difieren

> Sigue de la unidad 7: el ANOVA de un factor dijo que la tinta cambia el tiempo de secado ($F = 23{,}46$, $p < 0{,}001$). Ahora la pregunta es cuáles. Datos de `datos/secado.csv`, simulados por `verificacion/caso_estampa_sur_datos.py`.

El jefe de producción quiere saber si puede tratar igual a dos tintas en la programación del túnel, y cuál seca más rápido. Son 3 tintas, 10 prendas por tinta, $CME = 2{,}600$ con 27 gl.

Tukey a mano. $q_{0{,}95;\,3,\,27} = 3{,}506$, así que

$$HSD = 3{,}506\sqrt{\frac{2{,}600}{10}} = 1{,}788 \text{ min}$$

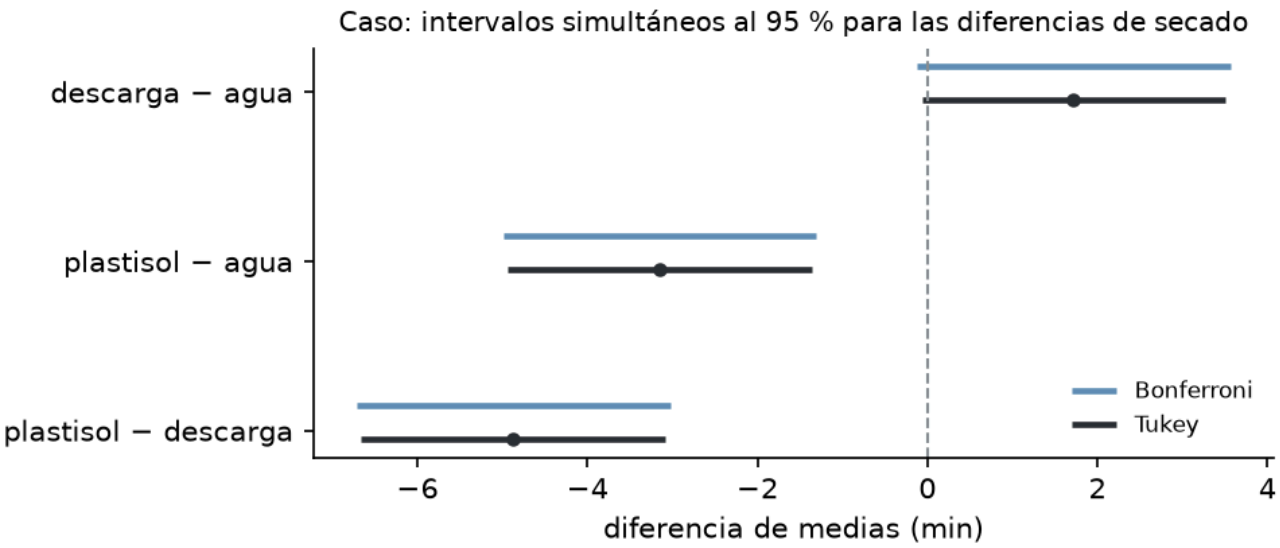
La salida de `pairwise_tukeyhsd` (la misma que imprime el script del caso):

group1	group2	meandiff	p-adj	lower	upper	reject
agua	descarga	1,7200	0,0611	-0,0679	3,5079	False
agua	plastisol	-3,1500	0,0005	-4,9379	-1,3621	True
descarga	plastisol	-4,8700	0,0000	-6,6579	-3,0821	True

(Un `p-adj` de 0,0000 es un valor p bajo 0,00005: se informa como $p < 0{,}001$.)

Contra Bonferroni. Con 3 pares, $t_{1-0{,}05/6;\,27} = 2{,}552$ y $ee = 0{,}7211$: la diferencia mínima es 1,841 min, algo mayor que el HSD.

Par	d (min)	t	p sin corregir	p Bonferroni	p Tukey
descarga − agua	1,72	2,39	0,024	0,073	0,061
plastisol − agua	-3,15	-4,37	< 0,001	< 0,001	< 0,001
plastisol − descarga	-4,87	-6,75	< 0,001	< 0,001	< 0,001



Letras.

Tinta	Media (min)	Grupo
plastisol	17,16	a
agua	20,31	b
descarga	22,03	b

Lectura.

- **El plastisol seca más rápido que las otras dos:** 3,15 min menos que la tinta al agua (entre 1,36 y 4,94) y 4,87 menos que la de descarga (entre 3,08 y 6,66). Las dos conclusiones sobreviven a Tukey y a Bonferroni. Si el plastisol se toma como la tinta de referencia del taller, Dunnett (valor crítico 2,334) dice lo mismo: las otras dos difieren de él con $p < 0{,}001$.
- **Agua y descarga no se distinguen con estos datos:** 1,72 min de diferencia, pero Tukey da $p = 0{,}061$ y Bonferroni 0,073. Una prueba t suelta ($p = 0{,}024$) habría dicho que difieren: es justo el error que esta unidad enseña a evitar. «No se distinguen» no es «son iguales»: el intervalo va de -0,07 a 3,51 min.
- **Decisión:** programar el túnel con dos tiempos, uno para plastisol y otro común para agua y descarga, sabiendo que la de descarga puede necesitar hasta unos 3,5 minutos más que la al agua.

Lo que pasa a la unidad 9. El CME de 2,600 incluye el efecto de la temperatura, que la unidad 7 dejó escondido en el error. La unidad 9 agrega la temperatura como segundo factor: el error baja y la comparación entre agua y descarga se vuelve a mirar con un error más chico.

---

14. Para seguir

En los libros del ramo.

- Montgomery, *Design and Analysis of Experiments* (Wiley), capítulo 3, el que fija el programa para el ANOVA de un factor; su parte sobre la interpretación de resultados trae comparaciones de pares, contrastes y comparaciones con un control.
- Kutner y otros, *Applied Linear Statistical Models* (McGraw-Hill, 2004), en sus capítulos de análisis de los efectos de los factores: Tukey, Scheffé y Bonferroni lado a lado.

Abiertos y gratis.

- NIST/SEMATECH, *e-Handbook of Statistical Methods*, sección 7.4.7 «How can we make multiple comparisons?» (en inglés), con Tukey, Scheffé y Bonferroni: https://www.itl.nist.gov/div898/handbook/prc/section4/prc47.htm
- Diez, Çetinkaya-Rundel y Barr, *OpenIntro Statistics* (PDF gratis, en inglés), sección 7.5 «Comparing many means with ANOVA», que cierra con comparaciones múltiples: https://www.openintro.org/book/os/

Con el tutor. La carpeta `tutor/` trae el contexto de este ramo. Pégalo al inicio de la conversación con cualquier IA y pídele, por ejemplo: «Dame una salida de Tukey con cinco grupos y pídeme las letras de agrupamiento y la recomendación; después corrígeme».
