Unidad 11 · Modelos lineales generalizados: logística y Poisson

Qué vas a poder hacer. Elegir la familia y el enlace de un modelo según el tipo de respuesta; ajustar una regresión logística y una de Poisson con `statsmodels`; traducir cada coeficiente a un odds ratio o a una razón de tasas; calcular una probabilidad o un conteo predicho; probar un coeficiente con Wald y un grupo de coeficientes con la razón de verosimilitud; detectar la sobredispersión y corregir los errores estándar cuando aparece.

Lo que necesitas antes. De la unidad 1, las cinco piezas de una prueba (hipótesis, estadístico, distribución bajo H_0, valor p, conclusión). De la unidad 4, el estadístico G de una tabla de contingencia. De la unidad 10, leer una tabla de coeficientes de regresión múltiple y la idea de «a igualdad de las demás variables».

Tiempo. Unas 6 horas: 2,5 de lectura con el ejemplo y el cuaderno, 3,5 de práctica.

---

1. La idea · cuando la respuesta no es una medida

La regresión de la unidad 10 supone que la respuesta es continua, que su varianza es la misma en todas partes y que el error es normal. Dos respuestas muy comunes en una empresa rompen las tres cosas:

- **Un sí o un no.** ¿El pedido llegó atrasado? ¿El lote salió con defecto? ¿El cliente renovó? La respuesta vale 0 o 1 y lo que interesa es la probabilidad p de que valga 1.
- **Un conteo.** Reclamos en el día, atascos en un turno, accidentes en el año. La respuesta es 0, 1, 2, … y lo que interesa es el promedio μ.

Si a esas respuestas se les ajusta una recta por mínimos cuadrados pasan tres cosas malas: la recta predice probabilidades bajo 0 o sobre 1 y conteos negativos; la varianza no es constante (en un 0 o 1 la varianza es $p(1-p)$, en un conteo de Poisson es igual a la media), y los valores p de la tabla dejan de valer. El **modelo lineal generalizado** (GLM) arregla las tres cosas sin perder lo bueno de la regresión: una ecuación lineal en los predictores, coeficientes que se interpretan uno por uno y pruebas para cada uno.

---

2. Las tres piezas de un GLM

Todo GLM se arma con tres decisiones:

1. **Componente aleatoria.** Qué distribución tiene la respuesta dado el valor de los predictores: normal, binomial (sí o no, o k éxitos en n), Poisson (conteos). Fija cómo se relacionan la media y la varianza.
2. **Predictor lineal.** La parte que ya conoces: $\eta = \beta_0 + \beta_1 x_1 + \cdots + \beta_k x_k$.
3. **Función de enlace g.** Conecta la media de la respuesta con el predictor lineal: $g(\mu) = \eta$. Su trabajo es llevar la media, que vive en un rango restringido, a toda la recta real, donde puede vivir η.

Respuesta	Componente aleatoria	Enlace canónico	El coeficiente se lee como
Medida continua (minutos, kilos)	normal	identidad: $\mu = \eta$	cambio en la media
Sí o no; k de n	binomial	logit: $\ln \frac{p}{1-p} = \eta$	e^{β} es un odds ratio
Conteo sin tope	Poisson	log: $\ln \mu = \eta$	e^{β} es una razón de tasas

La regresión lineal de la unidad 10 es el GLM normal con enlace identidad: no es otro método, es el caso particular. Lo que cambia en los otros dos es cómo se estima. Ya no se minimizan los cuadrados de los residuos; se buscan los β que hacen **más probable** lo observado (máxima verosimilitud). No hay fórmula cerrada en general: el computador itera (el algoritmo se llama IRLS) hasta converger. Con **un solo predictor binario** sí hay fórmula cerrada, y por eso el ejemplo y el caso empiezan ahí: se puede hacer a mano y comparar con Python.

Cuándo NO aplica tal cual. Si las observaciones no son independientes (mediciones repetidas del mismo cliente o del mismo lote), si la respuesta tiene más de dos categorías (se usa la logística multinomial u ordinal) o si los conteos tienen muchos más ceros de los que una Poisson permite.

---

3. Regresión logística

Probabilidad, odds y log-odds

Para una probabilidad p, los **odds** son $p/(1-p)$: cuántos «sí» hay por cada «no». Una probabilidad de 0,20 son odds de 0,25 (uno a cuatro); una de 0,50 son odds de 1. Los odds van de 0 a infinito; su logaritmo, el **log-odds** o logit, va de menos a más infinito, y eso es lo que el modelo iguala a una recta:

$$\ln \frac{p}{1-p} = \beta_0 + \beta_1 x_1 + \cdots + \beta_k x_k = \eta \qquad \Longleftrightarrow \qquad p = \frac{1}{1+e^{-\eta}}$$

La segunda forma (la función logística) es la que da la **probabilidad predicha**: se calcula η con los coeficientes y se pasa por la curva en S.

Cómo se lee un coeficiente

β_j es el cambio en el **log-odds** cuando x_j sube en 1, con el resto fijo. Como nadie piensa en log-odds, se exponencia:

$$OR_j = e^{\beta_j}$$

es el **odds ratio**: el factor por el que se **multiplican los odds** cuando x_j sube en 1. Un $OR = 1{,}5$ es «los odds suben 50 %»; un $OR = 0{,}8$ es «bajan 20 %»; $OR = 1$ es «no cambian». Si x sube en c unidades, los odds se multiplican por $e^{c\beta}$.

Lo que β no es: no es el cambio en la probabilidad. El efecto de x sobre p depende de dónde estás en la curva:

$$\frac{\partial p}{\partial x} = \beta\, p\,(1-p)$$

Es máximo cuando $p = 0{,}5$ (vale $\beta/4$) y se achica cerca de 0 y de 1. El mismo odds ratio puede ser un salto de 3 puntos porcentuales para un pedido de bajo riesgo y de 11 para uno de riesgo medio. Por eso se informa el odds ratio **y** algunas probabilidades predichas en casos típicos.

Con un solo predictor binario, a mano

Si x vale 0 o 1, el modelo tiene dos parámetros y dos grupos, y la máxima verosimilitud reproduce las proporciones de cada grupo. Con la tabla 2 × 2 (a_1 «sí» y b_1 «no» cuando $x = 1$; a_0 y b_0 cuando $x = 0$):

$$\hat{\beta}_0 = \ln \frac{a_0}{b_0} \qquad \hat{\beta}_1 = \ln \left(\frac{a_1/b_1}{a_0/b_0} \right) \qquad EE(\hat{\beta}_1) = \sqrt{\frac{1}{a_1} + \frac{1}{b_1} + \frac{1}{a_0} + \frac{1}{b_0}}$$

Es el odds ratio de la tabla de toda la vida. La intuición del error estándar: cada celda aporta $1/\text{conteo}$, así que la celda más chica manda; con pocas fallas el coeficiente es impreciso, aunque la muestra total sea grande.

---

4. Inferencia en un GLM · Wald, devianza y razón de verosimilitud

Prueba de Wald para un coeficiente

$$z = \frac{\hat{\beta}_j}{EE(\hat{\beta}_j)} \;\sim\; N(0,1) \text{ bajo } H_0 : \beta_j = 0 \qquad IC_{95\%}(OR_j) = e^{\hat{\beta}_j \pm 1{,}96\, EE(\hat{\beta}_j)}$$

Es lo que `statsmodels` muestra en la columna `z` y `P>|z|`. El intervalo se calcula en la escala de β y después se exponencia; por eso no es simétrico en torno al odds ratio. Si el intervalo del OR contiene el 1, el predictor no es significativo al 5 %.

Devianza

La **log-verosimilitud** $\ln L$ mide qué tan probable hace el modelo lo que se observó (es negativa; más cerca de 0 es mejor). La **devianza** es $D = -2 \ln L$ (medida contra el modelo saturado, que tiene un parámetro por observación): cumple el papel de la suma de cuadrados de los residuos.

- La **devianza nula** es la del modelo con solo intercepto.
- Con datos **agrupados** (muchos ensayos por fila, como pedidos por tramo de distancia), la devianza residual se compara con una χ^2 con $n - p$ grados de libertad: si es mucho mayor que sus grados de libertad, el modelo no ajusta. Con datos individuales 0 o 1 esa comparación no sirve.

Prueba de razón de verosimilitud

Para comparar un modelo reducido con uno completo que agrega q coeficientes:

$$G = D_{\text{reducido}} - D_{\text{completo}} = 2(\ln L_{\text{completo}} - \ln L_{\text{reducido}}) \;\sim\; \chi^2_q \text{ bajo } H_0$$

Contra el modelo nulo, G prueba si el modelo entero sirve (es el `LLR` del resumen de `statsmodels`). Contra el modelo sin una variable, prueba esa variable. Con muestras chicas o coeficientes grandes la razón de verosimilitud es más confiable que Wald. Con un predictor binario, G es exactamente el estadístico $G = 2\sum O \ln(O/E)$ de la tabla 2 × 2 de la unidad 4.

Para elegir entre modelos no anidados se usa el **AIC** $= -2\ln L + 2k$ (k = número de parámetros): menor es mejor; diferencias menores que 2 no distinguen.

La prueba en cinco pasos

Paso	En un GLM
Pregunta	¿La variable x_j cambia la probabilidad (o la tasa), a igualdad del resto?
Hipótesis	$H_0 : \beta_j = 0$ ($OR = 1$) contra $H_1 : \beta_j \neq 0$
Estadístico	z de Wald $\sim N(0,1)$, o $G \sim \chi^2_1$
Valor p	$2P(Z > \lvert z\rvert)$, o $P(\chi^2_1 > G)$
Conclusión	en el lenguaje del problema y con el tamaño: «la lluvia multiplica los odds de atraso por 3»

Clasificar · la matriz de confusión

Una logística da probabilidades. Para decidir (revisar el lote o no, llamar al cliente o no) se fija un **umbral**: si $\hat{p} \geq$ umbral se predice «sí». Cruzando lo predicho con lo real queda la matriz de confusión: verdaderos positivos (VP), falsos positivos (FP), falsos negativos (FN) y verdaderos negativos (VN). La **exactitud** es $(VP + VN)/n$; la **sensibilidad**, $VP/(VP + FN)$, es la fracción de los «sí» reales que se detectan; la **especificidad**, $VN/(VN + FP)$, la fracción de los «no» que se dejan pasar bien. Bajar el umbral sube la sensibilidad a costa de la especificidad; el umbral correcto lo fija el costo de cada error, no el 0,5.

---

5. Regresión de Poisson

El modelo

Para un conteo Y con media μ:

$$Y \sim \text{Poisson}(\mu) \qquad \ln \mu = \beta_0 + \beta_1 x_1 + \cdots + \beta_k x_k$$

El logaritmo garantiza $\mu > 0$ y vuelve multiplicativos los efectos: e^{β_j} es la **razón de tasas** (RR, *rate ratio*), el factor por el que se multiplica el conteo esperado cuando x_j sube en 1. Un $RR = 1{,}36$ es «36 % más eventos».

Con un solo predictor binario también hay fórmula cerrada: si el grupo 0 suma s_0 eventos en t_0 unidades de tiempo y el grupo 1 suma s_1 en t_1,

$$\hat{\lambda}_0 = \frac{s_0}{t_0} \qquad \widehat{RR} = \frac{s_1/t_1}{s_0/t_0} \qquad EE(\ln \widehat{RR}) = \sqrt{\frac{1}{s_0} + \frac{1}{s_1}}$$

Otra vez manda el grupo con menos eventos, no el con más días.

Exposición (offset)

Si las unidades observan tiempos distintos (una planta trabaja 52.000 horas y otra 61.000), comparar conteos crudos es injusto. Se modela la tasa: $\ln \mu_i = \ln t_i + \eta_i$, donde $\ln t_i$ entra con coeficiente fijo en 1 (el *offset*). En `statsmodels`: `offset=np.log(horas)`.

El supuesto que más se rompe · sobredispersión

La Poisson obliga a que la varianza sea igual a la media. En datos reales suele ser mayor (**sobredispersión**): hay días buenos y días malos por causas que el modelo no ve. El estimador del coeficiente sigue bien, pero los errores estándar salen **demasiado chicos** y los valores p demasiado optimistas. Se mide con

$$\hat{\phi} = \frac{X^2}{n-p} = \frac{1}{n-p}\sum_i \frac{(y_i - \hat{\mu}_i)^2}{\hat{\mu}_i}$$

Si $\hat{\phi} \approx 1$, la Poisson va bien. Si es claramente mayor (2, 4), se usa la **cuasi-Poisson** (mismo coeficiente, error estándar multiplicado por $\sqrt{\hat{\phi}}$; en `statsmodels`, `.fit(scale="X2")`) o una **binomial negativa**, que agrega un parámetro de dispersión. Si $\hat{\phi} < 1$, los errores estándar de la Poisson son conservadores y no hay que corregir nada.

---

6. Supuestos de los GLM y qué hacer si fallan

Supuesto	Cómo se revisa	Si falla
Observaciones independientes	cómo se tomaron los datos	modelos mixtos o errores agrupados
La familia es la correcta	varianza contra media; $\hat{\phi}$	cuasi-Poisson, binomial negativa
Linealidad en la escala del enlace	residuos de devianza contra cada x	transformar x, agregar un cuadrado
Sin separación perfecta (logística)	un x que predice el 0 o 1 sin error; coeficientes y EE enormes	juntar categorías, más datos, penalización
Suficientes eventos	regla práctica: unos 10 eventos (el resultado menos frecuente) por coeficiente	menos predictores

---

7. Ejemplo resuelto · Reparto Biobío y la imprenta de etiquetas

A · ¿La lluvia atrasa los pedidos?

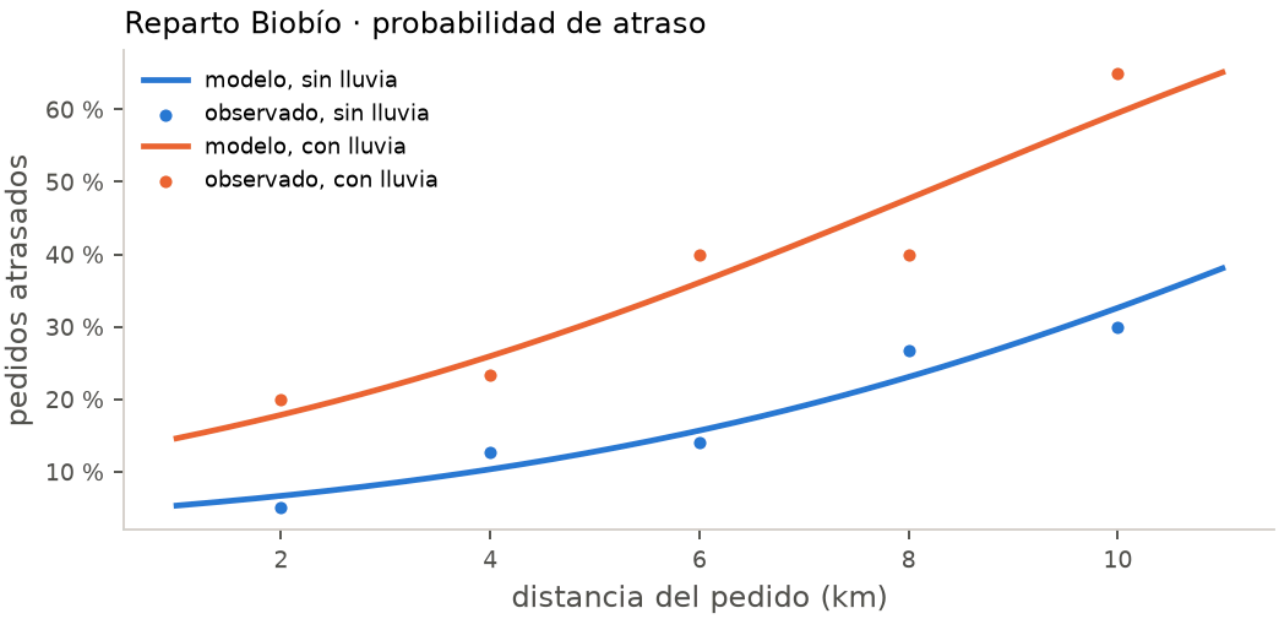
Reparto Biobío, una empresa de despacho en bicicleta y moto de Concepción, registró durante un mes cuántos pedidos salieron por tramo de distancia y cuántos llegaron fuera del plazo prometido, en días con y sin lluvia. Los datos están en `datos/u11_ejemplo_reparto.csv`.

Días sin lluvia:

km	Pedidos	Atrasados	Proporción
2	60	3	5,0 %
4	55	7	12,7 %
6	50	7	14,0 %
8	45	12	26,7 %
10	40	12	30,0 %

Días con lluvia:

km	Pedidos	Atrasados	Proporción
2	30	6	20,0 %
4	30	7	23,3 %
6	25	10	40,0 %
8	25	10	40,0 %
10	20	13	65,0 %



Supuestos. Cada pedido es un ensayo binario; los atrasos de pedidos distintos se toman como independientes (si un repartidor lleva varios pedidos juntos, no lo son del todo). Hay 87 atrasos para 3 coeficientes: sobra para la regla de los 10 eventos.

Paso 1 · a mano, solo la lluvia. Se juntan los tramos en una tabla 2 × 2:

	Atrasado	A tiempo	Total
Con lluvia	46	84	130
Sin lluvia	41	209	250

Con lluvia se atrasaron 46/130 (35,4 %); sin lluvia, 41/250 (16,4 %). Los odds son $46/84 = 0{,}5476$ y $41/209 = 0{,}1962$, y

$$OR = \frac{0{,}5476}{0{,}1962} = 2{,}792 \qquad \hat{\beta}_0 = \ln 0{,}1962 = -1{,}6288 \qquad \hat{\beta}_1 = \ln 2{,}792 = 1{,}0266$$

$$EE(\hat{\beta}_1) = \sqrt{\tfrac{1}{46} + \tfrac{1}{84} + \tfrac{1}{41} + \tfrac{1}{209}} = 0{,}2506 \qquad z = \frac{1{,}0266}{0{,}2506} = 4{,}10$$

$$IC_{95\%}(OR) = e^{1{,}0266 \pm 1{,}96 \cdot 0{,}2506} = (1{,}71;\ 4{,}56)$$

En cinco pasos: (1) ¿la lluvia cambia la probabilidad de atraso? (2) $H_0 : \beta_1 = 0$ contra $H_1 : \beta_1 \neq 0$. (3) $z = 4{,}10$, normal estándar bajo H_0. (4) p < 0,001; la razón de verosimilitud da $G = 16{,}81$ con 1 grado de libertad, también p < 0,001. (5) En días de lluvia los odds de atraso son 2,8 veces los de un día seco, con un intervalo de 1,71 a 4,56: el efecto es real y grande.

Paso 2 · con Python, agregando la distancia. Los datos están agrupados, así que la respuesta se le da al GLM binomial como «atrasados + a tiempo»:

```
import numpy as np, pandas as pd
import statsmodels.api as sm, statsmodels.formula.api as smf

rep = pd.read_csv("../datos/u11_ejemplo_reparto.csv")
rep["a_tiempo"] = rep.pedidos - rep.atrasados
g2 = smf.glm("atrasados + a_tiempo ~ km + lluvia", data=rep,
             family=sm.families.Binomial()).fit()
print(g2.summary())          # coeficientes, EE, z, devianza
print(np.exp(g2.params))     # odds ratios
```

El modelo con solo la lluvia (`~ lluvia`) devuelve exactamente $-1{,}6288$ y $1{,}0266$ con error estándar 0,2506: la fórmula de la tabla 2 × 2 y la máxima verosimilitud coinciden. El modelo completo:

Coeficiente	$\hat\beta$	EE	z	$e^{\hat\beta}$
Intercepto	$-3{,}1139$	0,3733	$-8{,}34$	
km	0,2389	0,0484	4,94	1,270
lluvia	1,1104	0,2631	4,22	3,04

- Cada kilómetro adicional multiplica los odds de atraso por 1,270 (27 % más), con la lluvia fija.
- A igual distancia, la lluvia multiplica los odds por 3,04 (IC 95 % de 1,81 a 5,08). Sin ajustar por distancia era 2,79: ajustar cambia el número, por eso se informa el ajustado.
- Razón de verosimilitud para la lluvia (modelo con km contra modelo con km y lluvia): $G = 18{,}07$; para la distancia, $G = 26{,}56$. Las dos con p < 0,001.
- Bondad de ajuste: la devianza nula es 45,75 y la residual 2,38 con 7 grados de libertad ($p = 0{,}94$). El modelo explica casi toda la variación entre tramos; no hay señal de falta de ajuste.

Probabilidades predichas, $\hat p = 1/(1 + e^{-\eta})$:

km	Sin lluvia	Con lluvia
2	6,7 %	17,9 %
6	15,7 %	36,1 %
10	32,6 %	59,5 %

Por ejemplo, a 10 km con lluvia, $\eta = -3{,}1139 + 0{,}2389 \cdot 10 + 1{,}1104 = 0{,}385$ y $\hat p = 1/(1 + e^{-0{,}385})$, es decir, 59,5 %. Fíjate en que el mismo $OR = 3{,}04$ es un salto de 11 puntos a 2 km y de 27 puntos a 10 km.

B · ¿El papel reciclado atasca más la impresora?

Una imprenta de etiquetas de Chillán anotó los atascos de su impresora en 10 turnos con papel virgen y 10 con papel reciclado (`datos/u11_ejemplo_atascos.csv`):

- Papel virgen: 1, 0, 2, 1, 3, 1, 0, 2, 1, 2 (suma 13).
- Papel reciclado: 3, 2, 4, 1, 3, 5, 2, 3, 4, 2 (suma 29).

A mano. $\hat\lambda_0 = 13/10 = 1{,}3$ y $\hat\lambda_1 = 29/10 = 2{,}9$ atascos por turno.

$$\widehat{RR} = \frac{2{,}9}{1{,}3} = 2{,}231 \qquad \hat\beta_0 = \ln 1{,}3 = 0{,}2624 \qquad \hat\beta_1 = \ln 2{,}231 = 0{,}8023$$

$$EE = \sqrt{\tfrac{1}{13} + \tfrac{1}{29}} = 0{,}3338 \qquad z = \frac{0{,}8023}{0{,}3338} = 2{,}40 \qquad IC_{95\%}(RR) = (1{,}16;\ 4{,}29)$$

El valor p de Wald es p = 0,016 y la razón de verosimilitud da $G = 6{,}25$, p = 0,012.

Supuesto de la Poisson. Las varianzas por grupo son 0,90 y 1,43, menores que las medias. El estadístico de Pearson es $X^2 = 10{,}68$ con 18 grados de libertad: $\hat\phi = 0{,}59$. No hay sobredispersión (la devianza residual, 12,70, también está bajo sus 18 grados de libertad), así que los errores estándar de la Poisson se pueden usar tal cual.

```
at = pd.read_csv("../datos/u11_ejemplo_atascos.csv")
gp = smf.glm("atascos ~ reciclado", data=at, family=sm.families.Poisson()).fit()
print(np.exp(gp.params["reciclado"]))       # razón de tasas
print(gp.pearson_chi2 / gp.df_resid)         # dispersión
```

Cómo se lee. Reparto Biobío ya sabe dónde está el riesgo: un pedido de 10 km en día de lluvia se atrasa más de la mitad de las veces. Tiene dos salidas: prometer un plazo más largo cuando llueve y la distancia supera los 6 km (donde el riesgo pasa del 36 %) o reforzar esos tramos con motos. La imprenta, por su parte, sabe que el papel reciclado duplica los atascos (entre 1,16 y 4,29 veces): 1,6 atascos más por turno. Si cada atasco cuesta 10 minutos de máquina, el ahorro del papel tiene que pagar esos minutos.

8. Errores típicos

Error	Cómo evitarlo
Leer β de la logística como cambio en la probabilidad («la lluvia sube el atraso en 1,11»)	β cambia el log-odds; e^{β} multiplica los odds; el cambio en p depende de dónde se parte: $\beta p(1-p)$
Confundir odds con probabilidad («OR de 3, entonces el triple de atrasos»)	Con p chica se parecen; con p grande no: 36 % y 59 % no son el triple
Ajustar una recta por mínimos cuadrados a un 0 o 1 o a un conteo	Predice fuera de rango y los valores p no valen: GLM binomial o Poisson
Usar la Poisson sin mirar la dispersión	Calcular $\hat{\phi}$; si pasa claramente de 1, cuasi-Poisson o binomial negativa
Comparar conteos de grupos con distinta exposición	Modelar la tasa con offset $\ln t$
Decir «no se rechaza, entonces la variable no influye»	No rechazar es falta de evidencia; mira el intervalo del OR: si va de 0,8 a 4, no sabes
Informar solo el valor p	Informar el OR o el RR con su intervalo y un par de probabilidades predichas (el tamaño del efecto)
Clasificar siempre con umbral 0,5	El umbral lo fija el costo de un falso negativo contra uno falso positivo
Creer que un buen valor p dice que el modelo ajusta	El valor p de un coeficiente no revisa los supuestos: devianza, dispersión y residuos

9. Práctica

Diez ejercicios: 11.1 a 11.4 básicos, 11.5 a 11.8 intermedios, 11.9 y 11.10 de desafío. Las pautas están en la sección 10. Usa $z_{0,975} = 1{,}96$.

11.1 · Despacho gratis y recompra (básico). Una tienda en línea ajusta una logística de la recompra en 60 días. El coeficiente de «tuvo despacho gratis» es $\hat{\beta} = 0{,}42$. (a) Calcula y lee el odds ratio. (b) Un cliente sin despacho gratis tiene probabilidad 0,30 de recomprar: calcula sus odds y su log-odds. (c) ¿Qué probabilidad tendría el mismo cliente con despacho gratis? ¿Subió 42 puntos? ¿Subió 42 %?

11.2 · Falla de una bomba (básico). Un plan de mantención modela la probabilidad de que una bomba falle en el mes: $\operatorname{logit}(p) = -4{,}1 + 0{,}035 \cdot \text{meses de uso} + 0{,}9 \cdot \text{turno noche}$. (a) Calcula la probabilidad de falla de una bomba de 24 meses en turno de día y de una de 60 meses en turno de noche. (b) Lee el odds ratio del turno de noche y el de 12 meses más de uso.

11.3 · Lluvia y llamadas a la mesa de ayuda (básico). Una Poisson de las llamadas por hora a la mesa de ayuda de una distribuidora eléctrica da $\ln \hat{\mu} = 0{,}85 + 0{,}31 \cdot \text{lluvia}$. Calcula las llamadas esperadas por hora sin lluvia y con lluvia, y la razón de tasas. ¿Cuánto por ciento más llamadas trae la lluvia?

11.4 · Elegir el modelo (básico). Para cada respuesta, di la componente aleatoria, el enlace y cómo se leería un coeficiente: (a) si un cliente renueva su contrato anual; (b) el número de llamadas que entran en una hora; (c) el tiempo de secado en minutos; (d) cuántas de 50 prendas revisadas salen defectuosas; (e) los accidentes del año en plantas de tamaños muy distintos.

11.5 · Recordatorio por WhatsApp (intermedio). Una cooperativa mandó un recordatorio por WhatsApp a 180 socios antes del vencimiento, y 132 pagaron a tiempo; de 170 socios sin recordatorio, pagaron a tiempo 98. Ajusta a mano la logística del pago a tiempo según el recordatorio: $\hat{\beta}_0$, $\hat{\beta}_1$, el error estándar de $\hat{\beta}_1$, la prueba de Wald en cinco pasos y el intervalo del 95 % del odds ratio. Escribe el código que lo confirma.

11.6 · Tres modelos anidados (intermedio). Con 480 clientes se ajustaron tres logísticas de la fuga: el nulo (solo intercepto, $\ln L = -312{,}4$), el modelo A (2 predictores, $\ln L = -298{,}7$) y el modelo B (A más 2 predictores, $\ln L = -295{,}9$). (a) Prueba si A sirve contra el nulo. (b) Prueba si B mejora a A. (c) Calcula el AIC de los tres. ¿Cuál usarías?

11.7 · Accidentes en dos plantas (intermedio). La planta A tuvo 14 accidentes con tiempo perdido en 52.000 horas-hombre; la planta B, 9 en 61.000. (a) Calcula la tasa de cada una por 100.000 horas. (b) Estima la razón de tasas de A contra B, su error estándar y la prueba de Wald. (c) Da el intervalo del 95 % y concluye. (d) Escribe el GLM con offset que lo confirma.

11.8 · El umbral de la alerta de fuga (intermedio). Una logística da la probabilidad de que doce clientes se vayan; después se vio quién se fue (1) y quién no (0):

Cliente	1	2	3	4	5	6	7	8	9	10	11	12
$\hat{p}$	0,83	0,74	0,62	0,53	0,46	0,41	0,36	0,29	0,23	0,18	0,12	0,07
Se fue	1	1	0	1	1	0	1	0	0	0	1	0

Arma la matriz de confusión con umbral 0,5 y con umbral 0,3, y calcula exactitud, sensibilidad y especificidad. Si perder un cliente cuesta diez veces lo que cuesta llamarlo, ¿qué umbral usarías?

11.9 · Llamadas abandonadas (desafío). En un centro de llamadas, la probabilidad de que el cliente cuelgue antes de ser atendido sigue $\operatorname{logit}(p) = -3{,}4 + 0{,}45 \cdot \text{minutos de espera}$. (a) Lee el odds ratio de un minuto y el de cinco minutos más de espera. (b) Calcula la probabilidad de abandono a los 2, 6 y 10 minutos, la pendiente $\beta p(1-p)$ en cada punto y cuánto sube p (en puntos porcentuales) con un minuto más. (c) ¿A qué espera la probabilidad llega a 50 %? ¿Cuál es el mayor aumento posible por minuto? (d) Explica a un jefe por qué «cada minuto sube el abandono en 0,45» está mal dicho.

11.10 · Fallas de dos líneas de envasado (desafío). Fallas diarias durante 12 días:

- Línea 1: 0, 1, 7, 0, 2, 9, 1, 0, 6, 1, 3, 0.
- Línea 2: 2, 8, 0, 11, 1, 4, 0, 9, 3, 12, 1, 5.

(a) Ajusta a mano la Poisson con la línea como predictor: razón de tasas, error estándar y prueba de Wald. (b) Calcula la media y la varianza de cada línea, el X^2 de Pearson y $\hat{\phi}$. (c) Corrige el error estándar con la cuasi-Poisson y repite la prueba. (d) ¿Cambia la conclusión? ¿Qué le dirías al jefe de planta que ya iba a cambiar la línea 2?

10. Pautas

11.1. (a) $OR = e^{0{,}42} = 1{,}522$: con despacho gratis los odds de recompra son 1,52 veces los de sin despacho gratis (52,2 % más odds). (b) Odds $= 0{,}30/0{,}70 = 0{,}4286$; log-odds $= \ln 0{,}4286 = -0{,}8473$. (c) Odds nuevos $= 0{,}4286 \cdot 1{,}522 = 0{,}6523$, y $p = 0{,}6523/1{,}6523$, es decir, 39,5 %. Subió unos 9,5 puntos, no 42 puntos ni 42 %. Lo que sube 52 % son los odds, no la probabilidad.

11.2. (a) Día, 24 meses: $\eta = -4{,}1 + 0{,}035 \cdot 24 = -3{,}26$ y la probabilidad es 3,7 %. Noche, 60 meses: $\eta = -4{,}1 + 2{,}1 + 0{,}9 = -1{,}10$ y la probabilidad es 25,0 %. (b) $e^{0{,}9} = 2{,}46$: a igual antigüedad, el turno de noche multiplica los odds de falla por 2,46. $e^{12 \cdot 0{,}035} = 1{,}52$: un año más de uso multiplica los odds por 1,52. La bomba vieja de noche merece la mantención primero.

11.3. Sin lluvia, $\hat{\mu} = e^{0{,}85} = 2{,}34$ llamadas por hora; con lluvia, $e^{0{,}85 + 0{,}31} = 3{,}19$. $RR = e^{0{,}31} = 1{,}363$: la lluvia trae 36,3 % más llamadas. Un turno de 8 horas con lluvia recibe unas 7 llamadas más: vale la pena reforzar la mesa en días de temporal.

11.4. (a) Binomial (Bernoulli) con enlace logit; e^{β} es un odds ratio de renovar. (b) Poisson con enlace log; e^{β} es una razón de tasas. (c) Normal con identidad (es la regresión de la unidad 10); si los tiempos son muy asimétricos y positivos, una gamma con enlace log. (d) Binomial con $n = 50$ y enlace logit; la respuesta se da como «defectuosas + buenas». (e) Poisson con enlace log y offset $\ln(\text{horas trabajadas})$; e^{β} es una razón de tasas por hora trabajada.

11.5. Odds con recordatorio $132/48 = 2{,}750$; sin recordatorio $98/72 = 1{,}361$. $OR = 2{,}020$, $\hat{\beta}_0 = \ln 1{,}361 = 0{,}3083$, $\hat{\beta}_1 = \ln 2{,}020 = 0{,}7033$. $EE = \sqrt{1/132 + 1/48 + 1/98 + 1/72} = 0{,}2291$. Cinco pasos: (1) ¿el recordatorio cambia el pago a tiempo? (2) $H_0 : \beta_1 = 0$, $H_1 : \beta_1 \neq 0$. (3) $z = 0{,}7033/0{,}2291 = 3{,}07$, normal estándar. (4) p = 0,002. (5) El recordatorio duplica los odds de pagar a tiempo: $IC_{95\%}(OR) = e^{0{,}7033 \pm 1{,}96 \cdot 0{,}2291} = (1{,}29;\ 3{,}17)$. En probabilidad, de 57,6 % a 73,3 %.

```
d = pd.DataFrame({"wsp": [1, 0], "pagan": [132, 98], "no_pagan": [48, 72]})
smf.glm("pagan + no_pagan ~ wsp", data=d, family=sm.families.Binomial()).fit().summary()
```

11.6. (a) $G = 2(-298{,}7 + 312{,}4) = 27{,}4$ con 2 grados de libertad; el crítico al 5 % es 5,99: p < 0,001, A sirve. (b) $G = 2(-295{,}9 + 298{,}7) = 5{,}6$ con 2 grados de libertad: p = 0,061. No hay evidencia suficiente al 5 % de que los dos predictores nuevos mejoren el modelo. (c) AIC: nulo 626,8; A 603,4; B 601,8. B gana por 1,6, menos de 2: los dos son prácticamente equivalentes. Con la prueba al límite y el AIC empatado, A es más simple y explica casi lo mismo; B se justifica solo si esos predictores son baratos de medir.

11.7. (a) A: $14/52.000 \cdot 100.000 = 26{,}9$; B: 14,8 accidentes por 100.000 horas. (b) $\widehat{RR} = 1{,}82$, $\ln \widehat{RR} = 0{,}6015$, $EE = \sqrt{1/14 + 1/9} = 0{,}4272$, $z = 1{,}41$, p = 0,159. (c) $IC_{95\%}(RR) = (0{,}79;\ 4{,}22)$. La planta A tiene casi el doble de tasa observada, pero con 23 accidentes en total la evidencia no alcanza: el intervalo va de una tasa menor a una cuatro veces mayor. No es «A es igual de segura»: es «todavía no se puede distinguir». (d) `smf.glm("acc ~ A", data=d, family=sm.families.Poisson(), offset=np.log(d.horas)).fit()`.

11.8.

Umbral	VP	FP	FN	VN	Exactitud	Sensibilidad	Especificidad
0,5	3	1	3	5	66,7 %	50,0 %	83,3 %
0,3	5	2	1	4	75,0 %	83,3 %	66,7 %

Con 0,3 se detectan 5 de las 6 fugas a cambio de llamar a 2 clientes que no se iban. Si una fuga cuesta diez veces una llamada, perder un cliente (FN) es el error caro: el umbral 0,3 es mejor (y podría bajar más).

11.9. (a) $e^{0{,}45} = 1{,}568$: cada minuto multiplica los odds de abandono por 1,57; $e^{5 \cdot 0{,}45} = 9{,}49$ para cinco minutos. (b)

Minutos	$\hat{p}$	Pendiente $\beta p(1-p)$	Un minuto más (puntos)
2	7,6 %	0,0315	3,8
6	33,2 %	0,0998	10,6
10	75,0 %	0,0843	7,5

(c) $p = 0{,}5$ cuando $\eta = 0$: $3{,}4/0{,}45 = 7{,}56$ minutos. La mayor pendiente es $\beta/4 = 0{,}1125$, unos 11 puntos por minuto, justo ahí. (d) 0,45 es el cambio del log-odds. En probabilidad, un minuto más pesa poco al principio (4 puntos a los 2 minutos) y mucho entre los 5 y los 9 minutos: ahí conviene poner el mensaje de «su llamada es importante» o la opción de que lo llamen de vuelta.

11.10. (a) Medias 2,50 y 4,67; $\widehat{RR} = 4{,}67/2{,}50 = 1{,}867$, $EE = \sqrt{1/30 + 1/56} = 0{,}2263$, $z = 2{,}76$, p = 0,006: con la Poisson, la línea 2 falla más. (b) Varianzas 9,73 y 18,61, unas cuatro veces las medias. $X^2 = 86{,}66$ con 22 grados de libertad, $\hat{\phi} = 3{,}94$: sobredispersión fuerte (hay días de 0 fallas y días de 9 a 12, en las dos líneas). (c) $EE_{\text{cuasi}} = 0{,}2263 \cdot \sqrt{3{,}94} = 0{,}4490$; $z = 1{,}39$, p = 0,165. (d) Sí cambia: la diferencia deja de ser significativa. La Poisson suponía que cada día era igual y subestimaba la incertidumbre a la mitad. Antes de cambiar la línea 2 conviene buscar qué hace que algunos días se disparen las fallas en las dos líneas (un insumo, un operador, un cambio de formato): esa causa común pesa más que la diferencia entre líneas.

---

11. Caso integrador · Estampa Sur, defectos y reclamos

> En la unidad 10 Estampa Sur explicó sus ventas semanales (una medida continua) con el precio y la publicidad. Ahora las respuestas son un sí o no (¿el lote salió con defecto?) y un conteo (¿cuántos reclamos llegaron hoy?). Los datos son simulados por `verificacion/caso_estampa_sur_datos.py` y están en `datos/lotes.csv` (160 lotes) y `datos/reclamos_dia.csv` (60 días).

Pregunta 1. ¿Qué sube la probabilidad de que un lote salga con defecto: la temperatura de curado, la tinta al agua o las dos?

A mano, solo la tinta. De 84 lotes con tinta al agua salieron con defecto 42/84; de 76 con plastisol, 19/76. Odds: $42/42 = 1{,}000$ y $19/57 = 0{,}333$, así que $OR = 3{,}00$, $\hat{\beta}_1 = \ln 3 = 1{,}0986$ y $EE = \sqrt{1/42 + 1/42 + 1/19 + 1/57} = 0{,}3432$; $z = 3{,}20$, p = 0,001.

Con Python, tinta y temperatura.

```
lotes = pd.read_csv("../datos/lotes.csv")
m4 = smf.logit("defecto ~ temperatura + tinta_agua", data=lotes).fit()
print(m4.summary()); print(np.exp(m4.params))
```

Coeficiente	$\hat{\beta}$	EE	z	$e^{\hat{\beta}}$
Intercepto	$\mathbf{-13{,}0754}$	2,8858	$\mathbf{-4{,}53}$	
temperatura (°C)	0,0734	0,0173	4,23	1,076
tinta al agua	1,2460	0,3744	3,33	3,48

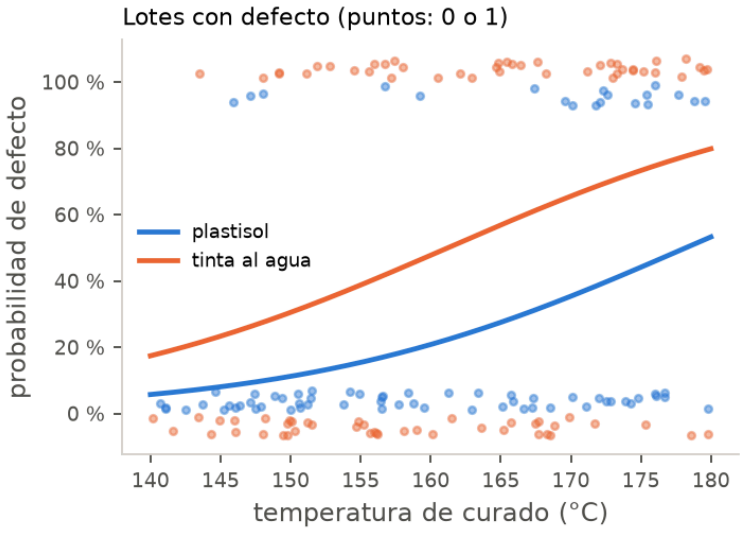
Prueba de la tinta en cinco pasos: (1) ¿la tinta al agua cambia la probabilidad de defecto a igual temperatura? (2) $H_0 : \beta_{\text{tinta}} = 0$. (3) $z = \mathbf{3{,}33}$, normal estándar; razón de verosimilitud contra el modelo sin tinta, $G = \mathbf{11{,}92}$ con 1 grado de libertad. (4) Las dos dan p < 0,001. (5) A igual temperatura, la tinta al agua multiplica los odds de defecto por **3,48** (IC 95 % de 1,67 a 7,24). Cada grado más multiplica los odds por 1,076; diez grados, por 2,08.

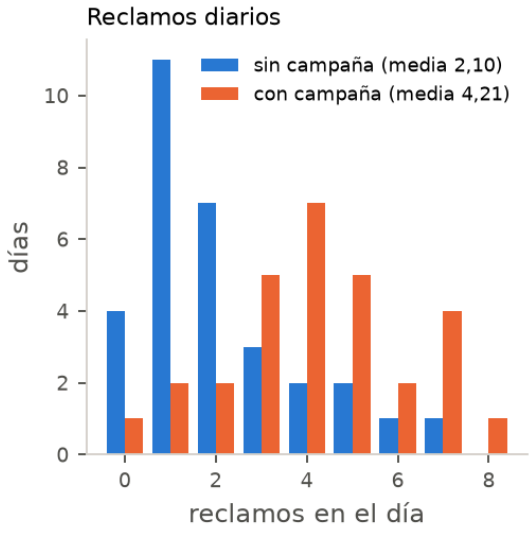
El modelo completo contra el nulo: devianza nula 212,70, residual 181,13, $G = \mathbf{31{,}57}$ con 2 grados de libertad, p < 0,001.

¿Por qué el OR pasó de 3,00 a 3,48? No es que la temperatura confunda: la temperatura media de los lotes es 160,7 °C con plastisol y 161,2 °C con tinta al agua, casi igual. Es una propiedad del odds ratio (no es «colapsable»): al agregar un predictor que explica parte de la variación, el OR de los demás se aleja de 1 aunque no haya confusión. Por eso se compara el OR ajustado con el ajustado, nunca con el de la tabla cruda.

Probabilidades predichas:

Temperatura	Plastisol	Tinta al agua
150 °C	11,2 %	30,5 %
160 °C	20,8 %	47,7 %
170 °C	35,4 %	65,5 %





Si el taller usara el modelo para decidir qué lotes revisar con umbral 0,5:

Real	Predicho con defecto	Predicho sin defecto
defecto	29	32
sin defecto	16	83

Exactitud 70,0 %, sensibilidad 47,5 %, especificidad 83,8 %: con 0,5 se escapa más de la mitad de los lotes malos. Para un control de calidad conviene un umbral más bajo.

Pregunta 2. ¿La campaña web trae más reclamos?

A mano. Sin campaña llegaron 65 reclamos en 31 días ($\hat{\lambda}_0 = 2{,}097$ por día); con campaña, 122 reclamos en 29 días ($\hat{\lambda}_1 = 4{,}207$). $\widehat{RR} = 4{,}207/2{,}097 = 2{,}01$, $\hat{\beta}_0 = 0{,}7404$, $\hat{\beta}_1 = 0{,}6963$, $EE = \sqrt{1/65 + 1/122} = 0{,}1536$, $z = 4{,}53$, p < 0,001, $IC_{95\%}(RR) = (1{,}48;\ 2{,}71)$. Razón de verosimilitud: $G = 21{,}66$. `smf.glm("reclamos ~ campana_web", family=Poisson())` da los mismos coeficientes.

Supuesto. Varianzas 3,22 y 3,96 para medias 2,10 y 4,21; $X^2 = 72{,}45$ con 58 grados de libertad, $\hat{\phi} = 1{,}25$ (devianza 77,34). Sobredispersión leve: con la cuasi-Poisson el error estándar sube en $\sqrt{1{,}25} = 1{,}12$, a 0,1716, y $z = 4{,}06$. La conclusión no cambia.

Lectura para Estampa Sur. (1) La tinta al agua triplica los odds de defecto y el calor los empuja más: la temperatura alta que en la unidad 9 acortaba el secado cuesta defectos. A 170 °C con tinta al agua, dos de cada tres lotes salen malos; conviene curar la tinta al agua cerca de 150 °C y aceptar el secado más largo, o revisar todos esos lotes. (2) Los días de campaña llegan el doble de reclamos. Pero ojo: el modelo cuenta reclamos por día, no por pedido. Si la campaña también duplica los pedidos, la calidad no empeoró. El paso siguiente es registrar los pedidos diarios y usar `offset=np.log(pedidos)`: así se mide la tasa de reclamos por pedido.

Pasa a la unidad 12. La tasa de defecto por proveedor se mira ahora con otra lente: en vez de preguntar si el dato rechaza una hipótesis, se pregunta qué tan probable es que la tasa de Algodones Sur supere el 6 %, combinando la historia del taller con los datos nuevos.

---

12. Para seguir

En los libros del ramo.

- Kutner, *Applied Linear Statistical Models* (McGraw-Hill, 2004), capítulo de regresión logística, regresión de Poisson y modelos lineales generalizados: el desarrollo completo de la máxima verosimilitud, la devianza y los diagnósticos.
- Casella y Berger, *Statistical Inference* (Cengage, 2021), lo que trata de modelos lineales generalizados y de pruebas de razón de verosimilitud: la teoría detrás de Wald y de G. El programa la fija para esta unidad.

Abierto y gratis. Roback y Legler, *Beyond Multiple Linear Regression: Applied Generalized Linear Models and Multilevel Models in R* (licencia CC BY-NC-SA 4.0), capítulos 4 (regresión de Poisson), 5 (los GLM como teoría unificada) y 6 (regresión logística). Los ejemplos están en R, pero la lectura de los modelos es la misma:

https://bookdown.org/roback/bookdown-BeyondMLR/

Con el tutor. Pega `tutor/contexto.md` al inicio de la conversación y pídele, por ejemplo: «Dame una tabla 2 × 2 nueva, déjame calcular el odds ratio y su intervalo a mano y después corrígeme la lectura en probabilidad para dos casos típicos».

Base abierta de ingeniería · Camilo Merino · Análisis de Datos · versión 0.1 (16-10-2026). Ejercicios y datos originales; las cifras se verifican con el script de la unidad.